ANALYSE DE SENSIBILITÉ GLOBALE RÉCURSIVE

Projet d'Analyse Statistique

9 mars 2026

François Moussinga et **Emmanuel Abondo** (X2023s)

Sous l'encadrement de :

Thierry Klein
Membre de l'Institut de Mathématiques de Toulouse (IMT)

ÉCOLE POLYTECHNIQUE

IP PARIS

Remerciements

Nous tenons tout d'abord à exprimer notre profonde gratitude à notre encadrant, **Monsieur Thierry Klein**, Professeur à l'ENAC et chercheur à l'Institut de Mathématiques de Toulouse. Nous le remercions chaleureusement pour son suivi attentif, sa disponibilité constante et la qualité de ses conseils tout au long de ce projet. Son expertise scientifique, associée à une approche pédagogique toujours conviviale et stimulante, a été déterminante dans l'accomplissement de nos recherches et la résolution des défis mathématiques et algorithmiques rencontrés.

Nous souhaitons également adresser nos remerciements au **Département de Mathématiques Appliquées (MAP)** de l'École polytechnique. Ce projet d'analyse statistique nous a offert une opportunité de recherche extrêmement enrichissante, nous permettant d'explorer en profondeur les enjeux contemporains de l'analyse de sensibilité globale et de la quantification des incertitudes. Les ressources et le cadre de travail d'excellence mis à notre disposition ont grandement contribué à la réussite de cette étude.

Enfin, nous remercions toutes les personnes qui, de près ou de loin, ont participé par leurs échanges et leurs relectures à l'aboutissement de ce rapport.

Résumé

Ce rapport explore l'estimation des indices de Sobol, piliers de l'analyse de sensibilité globale. Si la méthode classique de Monte-Carlo (*Pick-Freeze*) s'impose comme un standard, elle souffre d'un coût computationnel prohibitif et d'une structure statique inadaptée aux flux de données. Pour pallier ces limites, nous étudions l'algorithme stochastique d'*Online Pick-Freeze Mirror Descent* (OPF-MD), qui reformule l'estimation des sensibilités comme un problème d'optimisation convexe sur le simplexe.

Toutefois, nous démontrons que face à la malédiction de la dimensionnalité, une stratégie d'exploration uniforme voue cet algorithme à l'échec. L'apport de ce travail réside donc dans la conception d'un couplage innovant : en exploitant la Différentiation Algorithmique Adjointe (AAD) et les mesures de sensibilité basées sur le gradient (DGSM, inspirées de la PCA Différentielle), nous développons une méthode de ciblage adaptatif (*Auto-Targeting*). Les résultats numériques confirment que cette hybridation permet de filtrer instantanément le bruit combinatoire et d'isoler les variables critiques au sein de modèles fortement non-linéaires en très grande dimension.

TABLE DES MATIÈRES

1 Introduction **7**

2 Approches Préliminaires : L'Intuition Linéaire **7**
2.1 Le cas de référence : Modèle linéaire déterministe 7
2.2 Limites de la linéarisation par régression 8

3 Fondements de l'analyse de sensibilité globale **9**
3.1 Le théorème de décomposition de Hoeffding 9
3.2 Identité de la variance et indices de Sobol 10
3.2.1 Définition des indices de Sobol 11
3.2.2 Exemples d'application de la décomposition ANOVA-Hoeffding et calcul des indices de Sobol 12
3.2.3 Quelques propriétés intuitives des indices de Sobol 13

4 Estimation numérique des indices de Sobol : La méthode Pick-Freeze Monte-Carlo ([4, 5]) **15**
4.1 Le "Trick" du Pick-Freeze (Lemme de Covariance) 15
4.2 Construction des estimateurs numériques 16
4.3 Propriétés asymptotiques des estimateurs Pick-Freeze 16
4.3.1 Outils théoriques : La méthode Delta 17
4.3.2 Consistance des estimateurs 17
4.4 Normalité asymptotique (TCL) 17
4.5 Cas particulier : Indice d'ordre 2 18
4.6 simulation numérique du Pick-Freeze Monte Carlo 18
4.6.1 Convergence et Consistance de l'estimateur 18
4.6.2 Vitesse de convergence : Erreur moyenne globale 18
4.6.3 Normalité asymptotique (Validation du TCL) 20
4.7 Limites de la méthode Pick-Freeze classique et besoin d'approche stochastique . 20
4.7.1 Le coût computationnel : l'explosion du nombre d'appels 20
4.7.2 Le verrou de la dimensionnalité : de la linéarité à l'explosion exponentielle 21
4.7.3 Flux de données séquentiels et stockage 22

5 Estimation Dynamique par Online Mirror Descent **23**
5.1 Du Pick-Freeze Statique au Flux de Données 23
5.2 Le problème d'optimisation sur le simplexe 23
5.3 Descentes de gradient 25
5.3.1 Descente de gradient projeté 25
5.3.2 Descente miroir 26
5.4 Algorithme Online Pick-Freeze Mirror Descent (OPF-MD) 27
5.5 Résultats Expérimentaux 28

5.6 Le rôle critique du vecteur d'échantillonnage a_u : Réduction de Variance et Ciblage 33
5.6.1 Cas d'étude : Le problème de la parcimonie (Le "Réacteur Caché") 33

6 Perspectives : Vers un Auto-Ciblage par PCA Différentielle 34
6.1 La source : De la PCA classique à la PCA Différentielle [3] 35
6.2 Lien mathématique : Inégalités de Poincaré et Indices de Sobol 35
6.3 Le catalyseur technologique : La Différentiation Algorithmique Adjointe (AAD) 37
6.4 Implémentation de l'Auto-Targeting sur OPF-MD 38

7 Synthèse Globale des Performances 39

8 Conclusion Générale 41

1 INTRODUCTION

Le point de départ de toute analyse de sensibilité est la considération d'un modèle mathématique ou numérique, représenté par une fonction G, faisant le lien entre un vecteur d'entrée et une sortie scalaire :

$$Y = G(X_1, X_2, \ldots, X_d) = G(X) \tag{1}$$

où $X = (X_1, \ldots, X_d)$ est un vecteur de d variables aléatoires d'entrée, supposées **indépendantes** et distribuées selon une loi de probabilité connue. L'objectif est de quantifier la part de variabilité de la réponse $Y \in L^2$ attribuable à chaque composante (ou sous-famille de variables) de X.

2 APPROCHES PRÉLIMINAIRES : L'INTUITION LINÉAIRE

2.1 Le cas de référence : Modèle linéaire déterministe

Afin d'illustrer les propriétés fondamentales des indices de Sobol, considérons le cas où G est une fonction strictement linéaire des entrées $(X_j)_{1 \leq j \leq d}$ supposées indépendantes :

$$Y = G(X) = \beta_0 + \sum_{j=1}^{d} \beta_j X_j \tag{2}$$

Dans ce cadre déterministe, nous pouvons dériver analytiquement l'ensemble des mesures de sensibilité.

Dérivation des indices de premier ordre : Par définition, l'indice de premier ordre mesure la part de variance de Y imputable à la seule variabilité de X_i.

1. **Variance totale :** Par indépendance des variables d'entrée, la variance de la somme est égale à la somme des variances :

$$\mathrm{Var}(Y) = \sum_{j=1}^{d} \beta_j^2 \sigma_j^2 \quad \text{où } \sigma_j^2 = \mathrm{Var}(X_j) \tag{3}$$

2. **Espérance conditionnelle :** En fixant X_i, les autres variables X_j $(j \neq i)$ sont intégrées par rapport à leur loi :

$$\mathbb{E}[Y|X_i] = \beta_i X_i + \underbrace{\beta_0 + \sum_{j \neq i} \beta_j \mathbb{E}[X_j]}_{\text{Constante } C} \tag{4}$$

3. **Indice de Sobol S_i :** La variance de cette espérance conditionnelle est $\mathrm{Var}(\beta_i X_i + C) = \beta_i^2 \sigma_i^2$. On en déduit :

$$S_i = \frac{\beta_i^2 \sigma_i^2}{\sum_{j=1}^d \beta_j^2 \sigma_j^2} \tag{5}$$

Résultats structurels du modèle linéaire : Le modèle linéaire déterministe présente des propriétés remarquables qui servent de point de comparaison pour les modèles complexes :

— **Absence d'interactions :** Puisque G est une somme de fonctions univariées, les termes de la décomposition de Hoeffding(voir la relation ()) d'ordre supérieur à 1 sont nuls ($G_A = 0$ pour $|A| > 1$). Il n'y a donc aucune interaction entre les variables.

— **Équivalence avec l'indice total :** En l'absence d'interactions, l'indice de premier ordre S_i est rigoureusement égal à l'indice total S_{Ti}. Toute l'influence de X_i sur le modèle est directe.

— **Complétude de la décomposition :** La somme des indices de premier ordre est exactement égale à 1 :

$$\sum_{i=1}^d S_i = \frac{\sum_{i=1}^d \beta_i^2 \sigma_i^2}{\sum_{j=1}^d \beta_j^2 \sigma_j^2} = 1 \tag{6}$$

Cela signifie que 100% de la variance de la sortie est expliquée par les effets individuels des variables.

Transition vers le cas général : Dans ce cadre linéaire, la hiérarchie des variables est dictée par le produit de leur coefficient structurel β_i^2 et de leur incertitude d'entrée σ_i^2. Ce modèle représente l'idéal théorique où la sensibilité de premier ordre est parfaitement additive à 1.

Une question naturelle se pose alors : si G est non linéaire, pouvons-nous toujours nous ramener au cas linéaire par une simple régression ? Nous allons voir que si la régression fournit une linéarisation de G (au sens des moindres carrés), elle s'avère insuffisante pour l'analyse de sensibilité : les indices de Sobol de premier ordre ne somment plus à 1 du fait des interactions, et la régression produit souvent de mauvaises estimations de ces indices.

2.2 Limites de la linéarisation par régression

Face à une fonction G complexe, une approche courante consiste à chercher le meilleur substitut linéaire via une régression globale. On obtient alors un modèle de la forme $Y \approx \beta_0 + \sum \beta_i X_i$. Cependant, cette démarche soulève deux problèmes majeurs pour l'analyse de sensibilité :

1. **Le défaut d'additivité et les interactions :** Dans un modèle non linéaire, la décomposition de Hoeffding fait apparaître des termes d'ordre supérieur (interactions) :

$$\mathrm{Var}(Y) = \sum_i V_i + \sum_{i<j} V_{ij} + \cdots + V_{1\ldots d} \tag{7}$$

   L'approche par régression ignore par construction les termes $V_{ij}, V_{ijk}, \ldots$. En conséquence, la somme des indices de premier ordre $\sum S_i$ est strictement inférieure à 1. Ce "manque à gagner" dans la variance expliquée est le symptôme direct de l'existence d'interactions que la régression est incapable de quantifier.

2. **Mauvaise estimation des indices de premier ordre :** La régression linéaire cherche à minimiser l'erreur quadratique globale. Si la fonction G possède une forte courbure (par exemple une dépendance quadratique ou sinusoïdale centrée), la régression peut attribuer un coefficient β_i proche de zéro à une variable pourtant très influente.

   À titre d'exemple, si $G(X) = X^2$ sur un intervalle symétrique $[-a, a]$, la meilleure droite de régression est une constante horizontale ($\beta = 0$). L'indice de sensibilité issu de la régression serait nul, alors que la variable X est responsable de 100% de la variance de la sortie.

Ainsi, se ramener au cas linéaire par régression revient à projeter une réalité multidimensionnelle complexe sur un plan simplifié. Cette simplification conduit non seulement à une sous-estimation de l'influence totale des variables (en ignorant les interactions), mais peut également masquer totalement l'importance de variables clés. Ce constat motive le recours à une théorie sur les indices de Sobol et plus tard aux techniques d'échantillonnage (pour implémenter l'estimation de ces indices) de type **Pick-Freeze**.

3 FONDEMENTS DE L'ANALYSE DE SENSIBILITÉ GLOBALE

3.1 Le théorème de décomposition de Hoeffding

Pour traiter le cas général où G est une fonction non linéaire quelconque, nous nous appuyons sur la décomposition de Hoeffding (également appelée décomposition ANOVA). Ce théorème stipule que toute fonction G de carré intégrable, agissant sur des variables aléatoires indépendantes, peut être décomposée de manière unique en une somme de fonctions orthogonales.

Soit $Y = G(X_1, \ldots, X_d)$ avec X_i des variables aléatoires indépendantes. La décomposition s'écrit :

$$G(X) = G_0 + \sum_{i=1}^{d} G_i(X_i) + \sum_{1\le i<j\le d} G_{ij}(X_i, X_j) + \cdots + G_{1,\ldots,d}(X_1, \ldots, X_d) \tag{8}$$

Propriétés fondamentales de la décomposition : La puissance de ce théorème réside dans trois propriétés mathématiques cruciales qui garantissent la cohérence de l'analyse de sensibilité :

— **Centrage des termes :** À l'exception de la moyenne globale $G_0 = \mathbb{E}[Y]$, chaque terme de la décomposition est de moyenne nulle :

$$\mathbb{E}[G_u(X_u)] = 0 \quad \text{pour tout } u \subseteq \{1, \dots, d\}, u \neq \emptyset \tag{9}$$

— **Orthogonalité :** Les termes sont mutuellement orthogonaux dans l'espace L^2. Si $u \neq v$, alors :

$$\mathrm{Cov}(G_u(X_u), G_v(X_v)) = \mathbb{E}[G_u(X_u)G_v(X_v)] = 0 \tag{10}$$

Cette propriété est la clé de la décomposition de la variance : elle assure qu'il n'y a pas de "double comptage" de l'influence des variables.

— **Unicité et construction par projections :** Chaque terme est défini de manière unique par des espérances conditionnelles successives. Par exemple, l'effet propre de X_i est :

$$G_i(X_i) = \mathbb{E}[Y|X_i] - G_0 \tag{11}$$

Et l'interaction entre X_i et X_j est le résidu de l'influence conjointe une fois les effets de premier ordre soustraits :

$$G_{ij}(X_i, X_j) = \mathbb{E}[Y|X_i, X_j] - G_i(X_i) - G_j(X_j) - G_0 \tag{12}$$

3.2 Identité de la variance et indices de Sobol

Grâce à l'orthogonalité, la variance totale de la sortie Y est exactement égale à la somme des variances de chaque terme de la décomposition de Hoeffding :

$$\mathrm{Var}(Y) = \sum_{i=1}^{d} V_i + \sum_{1 \leq i < j \leq d} V_{ij} + \cdots + V_{1,\dots,d} \tag{13}$$

où $V_u = \mathrm{Var}(G_u(X_u))$, $u \subseteq \{1, \dots, d\}$.

C'est cette égalité qui permet de définir les **indices de Sobol** comme la part de variance expliquée par chaque sous-ensemble de variables :

$$S_u = \frac{V_u}{\mathrm{Var}(Y)} \tag{14}$$

On a bien : $\Sigma_u S_u = 1$

Contrairement à la régression linéaire(ou tout autre modèle qui essaie de fitter la sortie) qui tente d'ajuster une forme préconçue au modèle, le théorème de Hoeffding "écoute" la structure intrinsèque de G. Il révèle que la variance non expliquée par les indices de premier ordre ($\sum S_i < 1$) n'est pas une erreur de modèle, mais la mesure exacte du poids des **interactions** ($S_{ij}, S_{ijk}, \dots$). Cette décomposition fournit donc le cadre théorique complet pour quantifier l'importance de chaque entrée, quelle que soit la complexité de G. Les indices de Sobol seront au coeur de la suite de ce travail.

3.2.1 • Définition des indices de Sobol

Soit $X = (X_1, \dots, X_p)$ un vecteur aléatoire à composantes indépendantes et $Y = f(X) \in L^2$. Il existe une décomposition ANOVA–Hoeffding unique

$$f(X) = \sum_{A \subseteq \{1,\dots,p\}} f_A(X_A),$$

telle que :

$$f_\varnothing = \mathbb{E}[Y], \qquad \mathbb{E}[f_A(X_A)] = 0 \text{ pour } A \neq \varnothing,$$

et

$$\mathbb{E}[f_A(X_A)\, f_B(X_B)] = 0 \quad \text{pour } A \neq B.$$

On définit les composantes de variance

$$V_A = \mathrm{Var}(f_A(X_A))\,, \qquad \mathrm{Var}(Y) = \sum_{A \subseteq \{1,\dots,p\}} V_A.$$

Indices de Sobol exact-order (Hoeffding). Pour tout sous-ensemble non vide $A \subseteq \{1, \dots, p\}$,

$$S_A = \frac{V_A}{\mathrm{Var}(Y)}.$$

Indices de Sobol fermés (closed indices). Pour tout $U \subseteq \{1, \dots, p\}$,

$$S_U^{\text{clos}} = \sum_{A \subseteq U} S_A = \frac{\mathrm{Var}\Big(\mathbb{E}[Y \mid X_U]\Big)}{\mathrm{Var}(Y)}.$$

Indices de Sobol totaux (variable seule). Pour tout $i \in \{1, \dots, p\}$,

$$S_i^{\text{tot}} = \sum_{A:\, i \in A} S_A = 1 - \frac{\mathrm{Var}\Big(\mathbb{E}[Y \mid X_{-i}]\Big)}{\mathrm{Var}(Y)}.$$

Indices de Sobol totaux (groupe de variables). Pour tout $U \subseteq \{1, \dots, p\}$,

$$S_U^{\text{tot}} = \sum_{A:\, A \cap U \neq \varnothing} S_A = 1 - \frac{\mathrm{Var}\Big(\mathbb{E}[Y \mid X_{-U}]\Big)}{\mathrm{Var}(Y)}.$$

Remarque 1. *A partir du théorème de décomposition de Hoeffding, on peut prouver aisément par induction que pour tout sous-ensemble A on a :*

$$G_A(X_A) = \mathbb{E}(G(X) \mid X_A) - \sum_{A' \subsetneq A} G_{A'}(X_{A'}). \tag{15}$$

C'est d'ailleurs par cette formule que sont calculés les indices de Sobol théoriquement comme nous allons le voir dans les exemples suivants (lorsque cela est possible).

3.2.2 • Exemples d'application de la décomposition ANOVA-Hoeffding et calcul des indices de Sobol

Exemple 1 : Le modèle de Bascule Non-Linéaire ($d = 2$) Soient X_1, X_2 deux variables indépendantes suivant une loi uniforme $\mathcal{U}[-1, 1]$. Considérons le modèle défini par :

$$Y = G(X_1, X_2) = X_1^2 X_2 \tag{16}$$

Ce modèle illustre parfaitement le cas d'une variable (X_1) dont l'influence est invisible au premier ordre malgré son rôle structurel.

1. Variance totale Calculons les moments nécessaires pour $X \sim \mathcal{U}[-1, 1]$: $\mathbb{E}[X] = 0$, $\mathbb{E}[X^2] = 1/3$, $\mathbb{E}[X^4] = 1/5$.

— Moyenne globale : $m = \mathbb{E}[X_1^2]\mathbb{E}[X_2] = \frac{1}{3} \times 0 = 0$.
— Espérance du carré : $\mathbb{E}[Y^2] = \mathbb{E}[X_1^4]\mathbb{E}[X_2^2] = \frac{1}{5} \times \frac{1}{3} = \frac{1}{15}$.
— Variance totale : $V = \mathbb{E}[Y^2] - m^2 = \mathbf{\frac{1}{15}}$.

2. Calcul par induction des variances et indices exacts La décomposition de la variance s'opère par étapes récursives :

1. **Ordre 1 :**
   — $V_1 = \mathrm{Var}(\mathbb{E}[Y|X_1]) = \mathrm{Var}(X_1^2\mathbb{E}[X_2]) = \mathrm{Var}(0) = \mathbf{0}$.
   — $V_2 = \mathrm{Var}(\mathbb{E}[Y|X_2]) = \mathrm{Var}(X_2\mathbb{E}[X_1^2]) = \mathrm{Var}(\frac{1}{3}X_2) = \frac{1}{9} \times \frac{1}{3} = \mathbf{\frac{1}{27}}$.
2. **Ordre 2 (Induction) :** L'interaction V_{12} est définie comme la variance non expliquée par les effets d'ordre 1 :

$$V_{12} = V - (V_1 + V_2) = \frac{1}{15} - \frac{1}{27} = \frac{9-5}{135} = \mathbf{\frac{4}{135}} \tag{17}$$

Variable	**Principal (S_i)**	**Interaction (S_{12})**	**Total (S_{Ti})**	**Interprétation**
X_1	0	0,444	0,444	Modulateur pur
X_2	0,556	0,444	1,000	Porteur d'effet

Table 1 – Tableau comparatif des indices pour le modèle de Bascule ($V_{tot} = 0,0667$)

3. Synthèse et comparaison des indices **Analyse du gap :** On observe que $\sum S_i = 0,556 < 1$. Ce déficit confirme que $44,4\%$ de la variabilité du système réside exclusivement dans le couplage entre X_1 et X_2.

—

Exemple 2 : Modèle à couplage mixte par blocs ($d = 4$) Soient $X_1, X_2, X_3, X_4 \sim \mathcal{U}[0, 1]$ indépendantes ($m_i = 1/2, \sigma_i^2 = 1/12$). On définit :

$$Y = G(X) = X_1X_2 + X_3X_4^2 \tag{18}$$

1. Variance totale Par indépendance des blocs, $V = \mathrm{Var}(X_1X_2) + \mathrm{Var}(X_3X_4^2)$.
— $\mathrm{Var}(X_1X_2) = \mathbb{E}[X_1^2]\mathbb{E}[X_2^2] - (\mathbb{E}[X_1]\mathbb{E}[X_2])^2 = (1/3)^2 - (1/4)^2 = 7/144$.
— $\mathrm{Var}(X_3X_4^2) = \mathbb{E}[X_3^2]\mathbb{E}[X_4^4] - (\mathbb{E}[X_3]\mathbb{E}[X_4^2])^2 = (1/3)(1/5) - (1/6)^2 = 7/180$.
— $\mathbf{V} = \frac{\mathbf{7}}{\mathbf{144}} + \frac{\mathbf{7}}{\mathbf{180}} = \frac{\mathbf{7}}{\mathbf{80}} = \mathbf{0,0875}$.

2. Calcul par induction des composantes de variance
— **Effets propres (Ordre 1) :** $V_1 = V_2 = 1/48 \approx 0,0208$; $V_3 = 1/108 \approx 0,0093$; $V_4 = 1/45 \approx 0,0222$.
— **Interactions (Ordre 2) :**
  — $V_{12} = \mathrm{Var}(X_1X_2) - (V_1 + V_2) = \frac{7}{144} - \frac{6}{144} = \frac{\mathbf{1}}{\mathbf{144}}$.
  — $V_{34} = \mathrm{Var}(X_3X_4^2) - (V_3 + V_4) = \frac{21}{540} - (\frac{5}{540} + \frac{12}{540}) = \frac{\mathbf{4}}{\mathbf{540}} = \frac{\mathbf{1}}{\mathbf{135}}$.

Variable	**Premier ordre** (S_i)	**Fermé** (S_{cl})	**Total** (S_{Ti})	**Gap** ($S_{Ti} - S_i$)
X_1	0,238	0,238	0,317	0,079
X_2	0,238	0,238	0,317	0,079
X_3	0,106	0,106	0,190	0,084
X_4	0,254	0,254	0,339	0,085

Table 2 – Synthèse des indices de Sobol pour le modèle à couplage mixte ($d = 4$)

3. Comparaison des types d'indices **Analyse de l'écart :** Dans ce modèle, $\sum S_i \approx 0,836$. La remarque sur la décomposition de Hoeffding est ici illustrée par les $16,4\%$ de variance résiduelle. L'écart est plus marqué pour le second bloc (X_3, X_4), prouvant que la non-linéarité en X_4^2 amplifie la sensibilité de l'interaction par rapport aux effets linéaires.

3.2.3 • Quelques propriétés intuitives des indices de Sobol

Propriétés des indices de Sobol Voici quelques propriétés fondamentales des indices de Sobol qui permettent de mieux interpréter la structure du modèle G :

1. **Indépendance :** Si la fonction G ne dépend pas de la variable aléatoire X_i, alors l'indice de sensibilité S_A est nul pour tout sous-ensemble A contenant i ($S_A = 0$ si $i \in A$).
2. **Influence exclusive :** Si l'indice total d'un groupe de variables A vaut 1 ($S_A^{tot} = 1$), cela signifie que le modèle G dépend exclusivement des variables dont les indices sont inclus dans A.
3. **Interprétation de la hiérarchie :**
   — S_i quantifie la part de variabilité due à l'action de la variable X_i seule (on parle d'importance de premier ordre).
   — $S_{i,j}$ quantifie la part de variabilité due spécifiquement à l'interaction entre X_i et X_j, une fois les effets de premier ordre retirés.
   — *Exemple :* Dans le cas où $G(X) = a_4X_1X_2$, on obtient $S_1 = S_2 = 0$ mais $S_{1,2} = 1$. Cela signifie que prises individuellement, X_1 et X_2 n'ont aucune influence sur la variabilité, mais qu'elles sont conjointement responsables de la totalité de la variance.

4. **Lien avec l'espérance conditionnelle :** L'indice fermé pour un sous-ensemble A, noté S_A^{clos}, est défini par le rapport de la variance de l'espérance conditionnelle sur la variance totale :

$$S_A^{clos} = \frac{\mathrm{Var}[\mathbb{E}(G(X)|X_A)]}{\mathrm{Var}[G(X)]} \tag{19}$$

Proposition 1. *Soit $\mathcal{Y}$ l'ensemble de tous les sous ensembles de $\{1, \dots, p\}$.*

$$\mathrm{Var}(Y) = \sum_{u \in \mathcal{Y}} V_u, \qquad \textit{avec} \qquad V_u = \sum_{v \subset u} (-1)^{|u|-|v|} \mathrm{Var}\Big(\mathbb{E}[Y \mid X^i,\, i \in v]\Big) \geq 0. \tag{20}$$

Démonstration. Supposons la proposition vraie pour tout sous ensebles de taille $k \leq n-1$ Soit u un sous ensemble de $\{1, \dots, p\}$ de taille $k+1$

En passant la variance dans l'équation (13) on obtient :

$$V_u = \mathrm{Var}\Big(\mathbb{E}[Y \mid X^i,\ i \in u]\Big) - \sum_{\substack{v \subset u \\ v \neq u}} V_v \geq 0$$

En utilisant l'hypothèse de récurrence on a :

$$V_u = \mathrm{Var}\Big(\mathbb{E}[Y \mid X^i,\ i \in u]\Big) - \sum_{\substack{v \subset u \\ v \neq u}} \sum_{u' \subset v} (-1)^{|v|-|u'|} \mathrm{Var}\Big(\mathbb{E}[Y \mid X^i,\ i \in u']\Big).$$

La double somme dans le membre de droite est évidemment finie donc en utilisant le théorème de Fubini :

$$V_u = \mathrm{Var}\Big(\mathbb{E}[Y \mid X^i,\ i \in u]\Big) - \sum_{\substack{u' \subset u \\ u' \neq u}} \sum_{\substack{v \supset u' \\ v \subset u \\ v \neq u}} (-1)^{|v|-|u'|} \mathrm{Var}\Big(\mathbb{E}[Y \mid X^i,\ i \in u']\Big)$$

$$V_u = \mathrm{Var}\Big(\mathbb{E}[Y \mid X^i,\ i \in u]\Big) - \sum_{\substack{u' \subset u \\ u' \neq u}} \mathrm{Var}\Big(\mathbb{E}[Y \mid X^i,\ i \in u']\Big) \sum_{\substack{v \supset u' \\ v \subset u \\ v \neq u}} (-1)^{|v|-|u'|}$$

On peut remarquer que pour un sous ensemble u' inclus dans u :

$$\sum_{\substack{v \supset u' \\ v \subset u \\ v \neq u}} (-1)^{|v|-|u'|} = \sum_{i=|u'|}^{|u|-1} \sum_{\substack{v \supset u' \\ |v|=i \\ v \subset u \\ v \neq u}} (-1)^{i-|u'|} = \sum_{i=|u'|}^{|u|-1} \binom{|u|-|u'|}{i-|u'|} (-1)^{i-|u'|} = -(-1)^{|u|-|u'|}$$

Ainsi :

$$V_u = \mathrm{Var}\Big(\mathbb{E}[Y \mid X^i,\ i \in u]\Big) - \sum_{\substack{u' \subset u \\ u' \neq u}} \mathrm{Var}\Big(\mathbb{E}[Y \mid X^i,\ i \in u']\Big)(-1)^{|u|-|u'|}$$

$$V_u = \sum_{v \subset u} (-1)^{|u|-|v|} \mathrm{Var}\Big(\mathbb{E}[Y \mid X^i,\, i \in v]\Big)$$

□

Soit $S^* = (S_u)_{u\in\mathcal{Y}}$ et $\Sigma^* = (\Sigma_u)_{u\in\mathcal{Y}}$. L'équation (16) nous permet d'écrire :

$$S^* = M\Sigma^*, \qquad \text{avec } \forall (u,v) \in \mathcal{Y}\times\mathcal{Y}, \quad M_{u,v} = (-1)^{|u|-|v|}\,\mathbf{1}_{v\subset u}.$$

La matrice M est une matrice triangulaire inversible avec M^{-1} définit par :

$$\forall (u,v) \in \mathcal{Y}\times\mathcal{Y}, \qquad (M^{-1})_{u,v} = 1.$$

L'estimation des indices de sobol nous donne par transformation linéaire ceux des indices de sobol fermés. Cela nous sera très utile pour la méthode pick-freeze Online Mirror Descent.

On observe aussi par la même égalité que S^* appartient au simplexe définit par :

$$\Delta_q := \left\{ s = (s_u)_{u\in\mathcal{Y}} \;\middle|\; \forall u \in \mathcal{Y},\ s_u \geq 0, \quad s_\varnothing = 0, \quad \sum_{u\in\mathcal{Y}} s_u = 1 \right\}.$$

En règle générale, il est impossible de calculer explicitement les indices de Sobol de manière analytique. En effet, dans la grande majorité des applications concrètes, la fonction G est soit inconnue (données expérimentales), soit d'une complexité telle (codes de calcul intensifs) que les intégrales nécessaires au calcul des espérances conditionnelles sont irréalisables.

Face à cette "boîte noire", le statisticien doit alors mettre en œuvre des méthodes d'estimation statistiques pour quantifier l'importance des variables d'entrée. C'est ici qu'interviennent les techniques de type Monte-Carlo, et plus précisément la méthode de *Pick-Freeze Monte-Carlo*.

4 ESTIMATION NUMÉRIQUE DES INDICES DE SOBOL : LA MÉTHODE PICK-FREEZE MONTE-CARLO ([4, 5])

L'estimation directe des indices de Sobol est complexe car elle repose sur des espérances conditionnelles, souvent impossibles à intégrer analytiquement. Nous nous concentrons ici sur l'estimation des **indices fermés** (S^u_{cl}), car leur connaissance suffit à reconstruire l'intégralité des indices du modèle.

4.1 Le "Trick" du Pick-Freeze (Lemme de Covariance)

Le cœur de la méthode repose sur une astuce permettant de transformer une variance d'espérance conditionnelle en une simple covariance entre deux sorties du modèle.

Le principe de construction : Soit $Y = f(X_1, \dots, X_d)$. Pour un sous-ensemble de variables u, on définit une version "perturbée" du modèle, notée Y^u, construite ainsi :

— On **garde** les variables appartenant à u (on les "gèle").

— On **ré-échantillonne** toutes les autres variables (on en prend des copies indépendantes).

Lemme 1 (Lemme de covariance)**.** *Pour tout sous-ensemble u, on a l'égalité fondamentale :*

$$Var(\mathbb{E}[Y|X_u]) = Cov(Y, Y^u) \tag{21}$$

Idée de la preuve. En supposant $\mathbb{E}[Y] = 0$, on a $\mathrm{Cov}(Y, Y^u) = \mathbb{E}[YY^u]$. Par la loi de l'espérance totale, en conditionnant par X_u, les variables Y et Y^u deviennent indépendantes (car elles ne partagent que X_u). Ainsi, $\mathbb{E}[YY^u|X_u] = \mathbb{E}[Y|X_u]\mathbb{E}[Y^u|X_u] = (\mathbb{E}[Y|X_u])^2$, ce qui redonne la variance de l'espérance conditionnelle après intégration. □

4.2 Construction des estimateurs numériques

À partir d'un échantillon de taille N de couples (Y_i, Y_i^u), nous pouvons définir deux types d'estimateurs pour l'indice fermé $\hat{S}^u_{cl}$.

1. L'estimateur "Standard" ($S^u_{N,cl}$) C'est l'application directe de la formule de la covariance empirique divisée par la variance empirique.

$$S^u_{N,cl} = \frac{\frac{1}{N}\sum Y_i Y_i^u - (\frac{1}{N}\sum Y_i)(\frac{1}{N}\sum Y_i^u)}{\frac{1}{N}\sum Y_i^2 - (\frac{1}{N}\sum Y_i)^2} \tag{22}$$

2. L'estimateur "Optimisé" ($T^u_{N,cl}$) Puisque Y et Y^u suivent la même loi, nous disposons en réalité de $2N$ observations pour estimer la moyenne et la variance globale. L'estimateur de Janon *et al.*, plus robuste, utilise toute cette information :

$$T^u_{N,cl} = \frac{\frac{1}{N}\sum Y_i Y_i^u - \left[\frac{1}{2N}\sum(Y_i + Y_i^u)\right]^2}{\frac{1}{2N}\sum(Y_i^2 + (Y_i^u)^2) - \left[\frac{1}{2N}\sum(Y_i + Y_i^u)\right]^2} \tag{23}$$

Remarque 2. *L'estimateur $T^u_{N,cl}$ est généralement privilégié car il exploite mieux la structure symétrique du problème (le fait que Y et Y^u sont identiquement distribués), ce qui réduit légèrement la variance de l'estimation en pratique.*

4.3 Propriétés asymptotiques des estimateurs Pick-Freeze

L'étude statistique des estimateurs de Sobol repose sur deux piliers : la **consistance** (convergence vers la vraie valeur) et la **normalité asymptotique** (vitesse de convergence et intervalles de confiance).

4.3.1 • Outils théoriques : La méthode Delta

Pour établir la convergence en loi des estimateurs, nous utilisons la **Méthode Delta**. Elle permet de transférer un Théorème Central Limite (TCL) d'un vecteur de moments vers une fonction de ces moments (ici, le ratio définissant l'indice de Sobol).

Théorème 1 (Méthode Delta)**.** *Soit (T_N) une suite de vecteurs aléatoires dans $\mathbb{R}^k$ telle que $\sqrt{N}(T_N - \theta) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \Sigma)$. Si $\phi : \mathbb{R}^k \to \mathbb{R}^m$ est une fonction dérivable en θ, alors :*

$$\sqrt{N}(\phi(T_N) - \phi(\theta)) \xrightarrow{\mathcal{L}} \mathcal{N}\left(0, J_\phi(\theta)\Sigma J_\phi(\theta)^T\right) \tag{24}$$

où $J_\phi(\theta)$ est la matrice jacobienne de ϕ en θ.

4.3.2 • Consistance des estimateurs

La convergence presque sûre (p.s.) garantit que, pour un échantillon suffisamment grand, l'estimateur rejoint la valeur théorique de l'indice.

Théorème 2 (Consistance)**.** *Si $E(Y^2) < \infty$, alors les estimateurs standard $S^u_{N,cl}$ et optimisé $T^u_{N,cl}$ convergent presque sûrement vers l'indice de Sobol fermé S^u_{cl} quand $N \to \infty$:*

$$S^u_{N,cl} \xrightarrow{a.s.} S^u_{cl} \quad et \quad T^u_{N,cl} \xrightarrow{a.s.} S^u_{cl} \tag{25}$$

Note : Ce résultat découle directement de la Loi Forte des Grands Nombres appliquée aux moments d'ordre 1 et 2.

4.4 Normalité asymptotique (TCL)

Pour établir la vitesse de convergence en $1/\sqrt{N}$, une hypothèse plus forte sur les moments est requise.

Théorème 3 (TCL pour les indices de Sobol fermés)**.** *On suppose que $E(Y^4) < \infty$ (existence du moment d'ordre 4). Alors les estimateurs suivent une loi normale asymptotique :*

1. ***Pour l'estimateur standard :*** $\sqrt{N}(S^u_{N,cl} - S^u_{cl}) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \Gamma_{u,S})$
2. ***Pour l'estimateur optimisé :*** $\sqrt{N}(T^u_{N,cl} - S^u_{cl}) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \Gamma_{u,T})$

Remarque 3. *Il convient de noter que les hypothèses de finitude des moments, bien que techniquement nécessaires au cadre théorique, ne sont nullement restrictives dans le cadre des applications réelles. En pratique, la sortie Y d'un modèle physique ou d'un simulateur numérique est presque systématiquement* ***bornée*** *sur son domaine de définition (phénomènes de saturation, contraintes physiques, etc.). Or, pour une variable aléatoire bornée, les moments de tout ordre existent, garantissant ainsi la validité du Théorème Central Limite et de la méthode Delta sans perte de généralité.*

Expression des variances asymptotiques : La variance de l'erreur dépend de la structure de dépendance entre Y et sa copie Y^u. Pour l'estimateur optimisé T, la composante de la matrice de covariance est donnée par :

$$(\Gamma_{u,T})_{l,j} = \frac{\mathrm{Cov}(YY^{u_l}, YY^{u_j}) - S_{cl}^{u_l}\mathrm{Cov}(YY^{u_j}, M) - S_{cl}^{u_j}\mathrm{Cov}(YY^{u_l}, M) + S_{cl}^{u_l}S_{cl}^{u_j}\mathrm{Var}(M)}{(\mathrm{Var}(Y))^2} \quad (26)$$

où M représente la moyenne des carrés des observations disponibles.

Remarque 4. *L'hypothèse $E(Y^4) < \infty$ est cruciale. Comme l'indice de Sobol fait intervenir des variances (moments d'ordre 2), le TCL appliqué à ces variances nécessite l'existence de moments d'ordre deux pour les carrés, soit des moments d'ordre 4 pour la sortie Y.*

4.5 Cas particulier : Indice d'ordre 2

Si l'on considère l'estimation d'un seul indice d'ordre 2 ($u = \{i, j\}$), la variance asymptotique se simplifie. Pour l'estimateur optimisé, elle prend la forme :

$$\Gamma_{u,T} = \frac{\mathrm{Var}(YY^u) - 2S_{cl}^u\mathrm{Cov}(YY^u, Y^2) + (S_{cl}^u)^2\frac{\mathrm{Var}(Y^2)+\mathrm{Cov}(Y^2,(Y^u)^2)}{2}}{(\mathrm{Var}(Y))^2} \quad (27)$$

4.6 simulation numérique du Pick-Freeze Monte Carlo

Cette section présente la validation numérique des estimateurs de Sobol sur le modèle d'Ishigami, défini par $Y = \sin(X_1) + 7\sin^2(X_2) + 0.1X_3^4\sin(X_1)$. Les variables d'entrée sont i.i.d. suivant une loi $\mathcal{U}[-\pi, \pi]$.

4.6.1 • Convergence et Consistance de l'estimateur

Le premier objectif est de vérifier expérimentalement le **Théorème 4.4** (convergence presque sûre). Pour cela, nous faisons varier la taille de l'échantillon N de 10^2 à 10^4.

Commentaires : Comme illustré sur la Figure 1, les estimations des trois indices (S_1, S_2, S_3) se stabilisent autour de leurs valeurs analytiques respectives $(0.3139, 0.4424, 0.0)$ à mesure que N augmente. On observe que l'indice S_3 est correctement identifié comme nul, confirmant que X_3 n'a aucun effet de premier ordre.

4.6.2 • Vitesse de convergence : Erreur moyenne globale

Conformément au théorème 4.5., l'erreur d'estimation doit décroître proportionnellement à $1/\sqrt{N}$. Pour évaluer la précision globale du système, nous calculons l'erreur absolue moyenne (MAE) sur l'ensemble du vecteur $\mathbf{S} = (S_1, S_2, S_3)$.

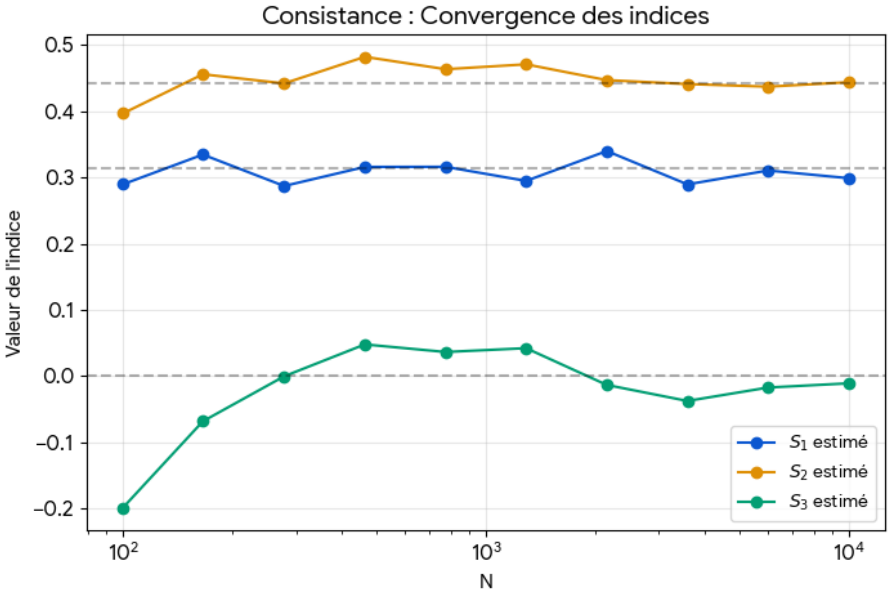

Figure 1 – Évolution des indices de Sobol estimés en fonction de N.

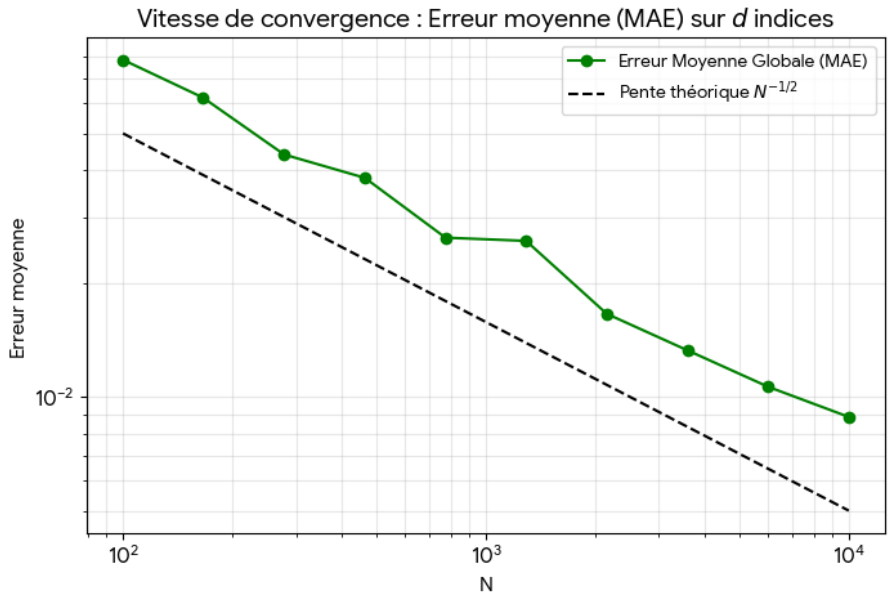

Figure 2 – Erreur absolue moyenne globale en échelle log-log.

Commentaires : La Figure 2 montre la MAE globale calculée sur 30 répétitions pour chaque point. La courbe suit fidèlement la pente théorique en $N^{-1/2}$ (représentée en pointillés). Cela valide la performance de l'estimateur Pick-Freeze : l'erreur moyenne est divisée par 10 lorsque la taille de l'échantillon est multipliée par 100.

4.6.3 • Normalité asymptotique (Validation du TCL)

Enfin, nous vérifions le **Théorème 4.5** en analysant la distribution de l'erreur normalisée pour S_1 sur 500 simulations indépendantes avec $N = 1500$.

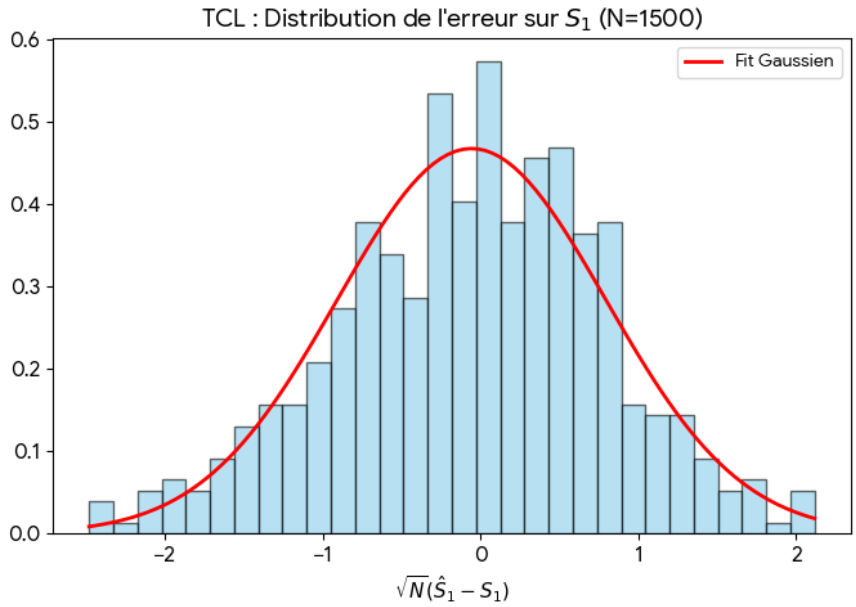

Figure 3 – Distribution de l'erreur normalisée $\sqrt{N}(\hat{S}_1 - S_1)$ et ajustement gaussien.

Commentaires : L'histogramme des erreurs normalisées (Figure 3) présente une forme en cloche centrée en zéro. L'ajustement par une loi normale confirme la validité de la méthode Delta. Cette propriété est cruciale en pratique car elle permet de construire des **intervalles de confiance** autour des estimations de sensibilité.

4.7 Limites de la méthode Pick-Freeze classique et besoin d'approche stochastique

Malgré sa robustesse théorique, la méthode Pick-Freeze de Monte-Carlo se heurte à des contraintes de performance majeures. Dans les applications réelles, le code de calcul est souvent très coûteux en temps, ce qui limite l'usage des approches de type.

4.7.1 • Le coût computationnel : l'explosion du nombre d'appels

Le principal verrou de l'approche Monte-Carlo réside dans le nombre d'évaluations de la fonction G requises. Pour estimer simultanément un vecteur de k indices de Sobol fermés , la

méthode nécessite de générer un échantillon de base et k échantillons "ressourcés". Le coût total en appels à la fonction G est de :

$$C_{total} = N \times (k+1) \tag{28}$$

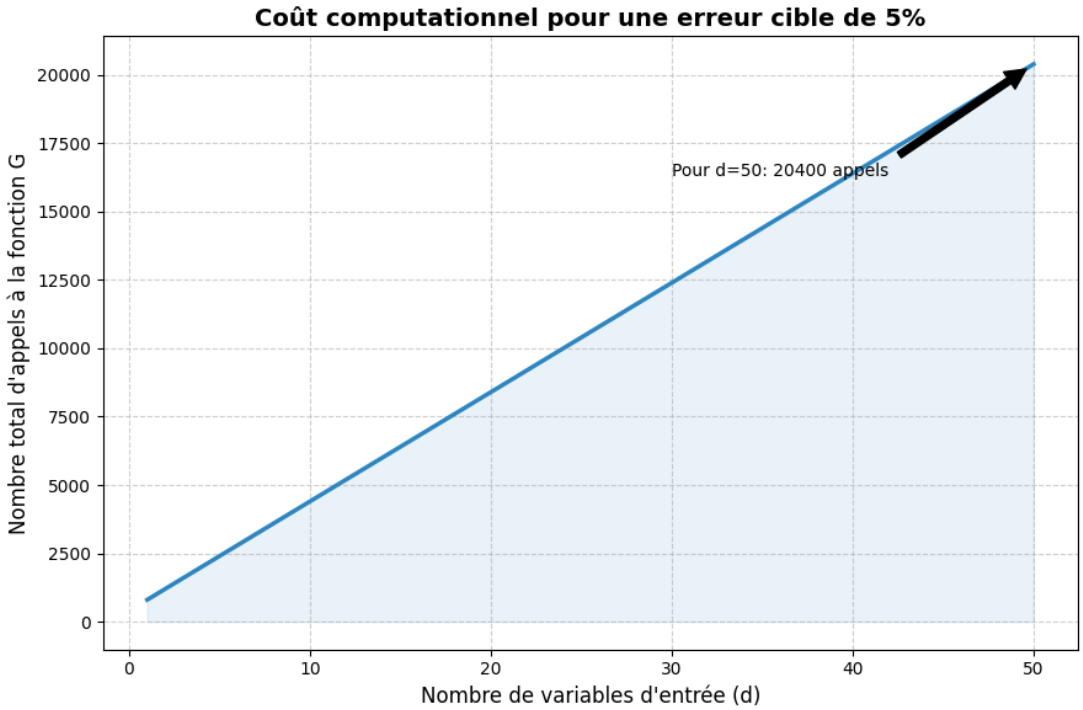

Figure 4 – Évolution de l'erreur d'estimation en fonction du coût total d'appels. Pour une dimension élevée ($d = 20$), le nombre d'appels nécessaires pour atteindre une précision acceptable devient prohibitif.

Analyse du coût : Comme illustré dans la Figure 4, à budget de calcul constant, l'erreur d'estimation augmente drastiquement avec la dimension. Pour des simulateurs complexes où chaque exécution dure plusieurs heures , la méthode Pick-Freeze devient impraticable dès que le nombre d'entrées suivies augmente.

4.7.2 • Le verrou de la dimensionnalité : de la linéarité à l'explosion exponentielle

La complexité de l'analyse est intrinsèquement liée au nombre d'interactions que l'on souhaite capturer. Soit d le nombre de variables d'entrée :

— **Analyse au premier ordre :** Si l'on se restreint aux d indices de premier ordre ($k = d$), le coût est de $N(d+1)$. Bien que mathématiquement linéaire en d, ce coût est prohibitif en pratique car chaque nouvelle variable impose N simulations supplémentaires ($N \geq 10^4$ pour la convergence).

— **Analyse exhaustive :** La décomposition de Hoeffding implique théoriquement $2^d - 1$ indices de Sobol . L'estimation statistique du vecteur complet devient alors exponentielle $(N \times 2^d)$. Cette "malédiction de la dimension" rend toute analyse exhaustive strictement impossible par les méthodes classiques en haute dimension.

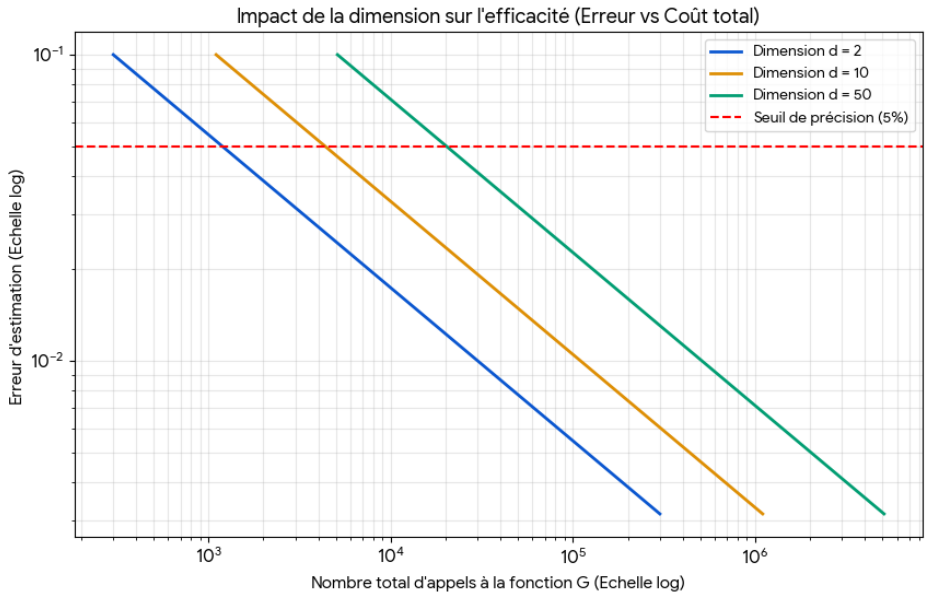

Figure 5 – Nombre d'appels à la fonction G requis pour stabiliser l'erreur en fonction de la dimension d.

Commentaire : La Figure 5 illustre cette explosion. Pour $d = 50$, l'analyse de premier ordre coûte déjà 17 fois plus cher qu'un modèle à 2 variables. L'ajout des interactions d'ordres supérieurs rend le coût totalement hors de portée d'un budget de calcul standard.

4.7.3 • Flux de données séquentiels et stockage

L'article de *Costa et al. (2025)* souligne que l'approche "Batch" est également limitée par sa nature statique :

— **Stockage :** L'estimateur classique impose de conserver en mémoire $N(k+1)$ résultats de simulations pour calculer les moments empiriques.

— **Inadaptabilité :** Elle ne permet pas de mettre à jour les indices au fil de l'eau si les données arrivent de manière séquentielle, obligeant à recalculer l'intégralité des sommes à chaque nouvel échantillon.

Vers une solution stochastique : Pour pallier ces défauts, il est nécessaire de passer à un algorithme **itératif** (on-line) capable de mettre à jour le vecteur d'indices à chaque nouvelle simulation reçue, sans stockage massif, et en maintenant un coût réduit à seulement **2 appels**

par itération (Y et Y^u). C'est dans ce cadre que s'inscrit la **Descente de Miroir (Mirror Descent)**.

5 ESTIMATION DYNAMIQUE PAR ONLINE MIRROR DESCENT

C'est ici que réside le cœur de notre étude, s'appuyant sur les travaux de [1].

5.1 Du Pick-Freeze Statique au Flux de Données

La méthode *Pick-Freeze* classique estime S_i via la covariance entre la sortie originale Y et une sortie perturbée Y^u. Cependant, l'approche par blocs est coûteuse en mémoire et inadaptée aux flux de données.

Elle permet d'estimer chaque indice de sobol de manière individuel ce qui apporte un facteur de 2^p pour estimer tous les indices. Elle n'est pas séquentielle donc nécessite d'avoir à dispostion l'entièreté des données utiisés pour estimer.

La méthode dynamique vient répondre à ces problèmes. Comme son nom l'indique elle traite les données en ligne et met à jour l'entièreté des indices de Sobol à chaque ajout d'échantillon enlevant le facteur de 2^n pour les appels de la fonction f

5.2 Le problème d'optimisation sur le simplexe

L'innovation majeure consiste à voir le vecteur des indices $S = (S_1, \dots, S_d)$ comme la solution d'un problème de minimisation d'un risque convexe sur le simplexe de probabilité Δ_d :

$$S^* = \arg\min_{s \in \Delta_d} \mathcal{R}(s) \tag{29}$$

Proposition 2. *Soient X et Y deux variables aléatoires réelles de carré intégrable. On suppose $Var(Y) > 0$. Alors*

$$\theta^* = \arg\min_{\theta \in \mathbb{R}} \mathbb{E}\Big[\big(\theta\,(Y - \mathbb{E}[Y]) - (X - \mathbb{E}[X])\big)^2\Big]$$

est unique et donné par

$$\theta^* = \frac{Cov(X, Y)}{Var(Y)}.$$

Démonstration. On pose

$$A := Y - \mathbb{E}[Y], \qquad B := X - \mathbb{E}[X].$$

On considère la fonction

$$f(\theta) = \mathbb{E}\Big[(\theta A - B)^2\Big], \qquad \theta \in \mathbb{R}.$$

En développant le carré et en utilisant la linéarité de l'espérance, on obtient

$$f(\theta) = \theta^2 \mathbb{E}[A^2] - 2\theta \mathbb{E}[AB] + \mathbb{E}[B^2].$$

La fonction f est un polynôme quadratique en θ, strictement convexe dès que $\mathbb{E}[A^2] > 0$, c'est-à-dire $\mathrm{Var}(Y) > 0$. Son minimum est donc atteint lorsque sa dérivée s'annule :

$$f'(\theta) = 2\theta \mathbb{E}[A^2] - 2\mathbb{E}[AB] = 0.$$

On en déduit

$$\theta^* = \frac{\mathbb{E}[AB]}{\mathbb{E}[A^2]}.$$

En revenant aux variables initiales, on reconnaît

$$\mathbb{E}[AB] = \mathrm{Cov}(X, Y), \qquad \mathbb{E}[A^2] = \mathrm{Var}(Y),$$

d'où

$$\theta^* = \frac{\mathrm{Cov}(X, Y)}{\mathrm{Var}(Y)}.$$

□

Cette proposition associé au Pick Freeze Trick nous permet d'écrire les indices de sobol fermés comme solution d'un probème d'optimisation. Pour tout u dans $\{1, \ldots, p\}$:

$$\Sigma_u^* = \arg\min_{\theta \in [0,1]} \psi_u(\theta), \qquad \text{où } \psi_u(\theta) = \mathbb{E}\Big[\Big((Y - \mathbb{E}[Y])\,\theta - \Big(Y^{(u)} - \mathbb{E}[Y]\Big)\Big)^2\Big].$$

En définissant pour tout a et x dans $\mathcal{Y}$ par : $\Psi^a(x) = \frac{1}{2}\sum_{u \in \mathcal{Y}} \psi_u(x_u)$

On obtient une fonction qui est minimisé par Σ^*. Par transformation linéaire S^* minimise la fonction définie par $\Phi(u) = \Psi(M^{-1}u)$

Corollaire 1 (Caractérisation variationnelle de $\mathbf{S}^*$)**.** *Pour toute loi de probabilité discrète positive $a = (a_u)_{u \in \mathcal{Y}}$ te que $\min_{u \in \mathcal{Y}}(a_u) > 0$, la collection des indices de Sobol $\mathbf{S}^*$ est définie de manière unique par*

$$\mathbf{S}^* = \arg\min_{s \in \Delta_q} \Phi^a(s). \tag{14}$$

où la fonctionnelle Φ^a peut s'écrire comme une fonction fortement convexe, représentée sous forme d'une espérance :

$$\Phi^a(s) = \mathbb{E}\Big[\Big((Y - \mathbb{E}[Y])\,[M^{-1}s]_U - \Big(Y^{(U)} - \mathbb{E}[Y]\Big)\Big)^2\Big]. \tag{15}$$

où $U \sim \mathcal{L}_{\mathcal{Y}}^a$ et, conditionnellement à U, (Y, Y^U) constitue un échantillon de type Pick–Freeze (voir la Proposition 2.1).

Les fonctions ψ_u et par exentensions Ψ_a et Φ_a sont fortement convexes ce qui nous permet de résoudre le problème d'optimisation par un algorithme de déscente de gradient.

5.3 Descentes de gradient

Le probème consisite à trouver le minimiseur de la fonction fortement convexe Φ_a. Pour ce faire nous allons explorer de algorithme de descente de gradient

5.3.1 • Descente de gradient projeté

Soit la suite $(\theta_n)_{n\geq 0}$ définie par $\theta_0 \in \Delta_q$ et :

$$\theta_{n+1} \in \arg\min_{\theta\in\Delta_q} \left\{ \Phi(\theta_n) + \langle \nabla\Phi(\theta_n), \theta - \theta_n \rangle + \frac{1}{2\gamma_{n+1}} \|\theta - \theta_n\|_2^2 \right\}. \tag{30}$$

En posant

$$z_n := \theta_n - \gamma_{n+1} \nabla\Phi(\theta_n),$$

ce problème est équivalent à

$$\theta_{n+1} = \arg\min_{\theta\in\Delta_q} \|\theta - z\|_2^2.$$

Proposition 3 (Projection euclidienne sur le simplexe)**.** *Soit $z \in \mathbb{R}^q$ et*

$$\Delta_q = \{\theta \in \mathbb{R}^q : \ \theta_i \geq 0, \ \sum_{i=1}^q \theta_i = 1\}.$$

Alors le problème

$$\min_{\theta\in\Delta_q} \ \frac{1}{2}\|\theta - z\|_2^2$$

admet une solution unique $\theta^\star$ donnée par

$$\theta_i^\star = \max(z_i - \tau, 0),$$

où $\tau \in \mathbb{R}$ est tel que $\sum_{i=1}^q \max(z_i - \tau, 0) = 1$.

Démonstration. On considère le lagrangien

$$\mathcal{L}(\theta, \lambda, \mu) = \frac{1}{2}\sum_{i=1}^q (\theta_i - z_i)^2 + \lambda\Big(\sum_{i=1}^q \theta_i - 1\Big) - \sum_{i=1}^q \mu_i\theta_i,$$

où $\lambda \in \mathbb{R}$ et $\mu_i \geq 0$. Les conditions Karush–Kuhn–Tucker s'écrivent :

$$\theta_i - z_i + \lambda - \mu_i = 0, \qquad \theta_i \geq 0, \qquad \mu_i \geq 0, \qquad \mu_i\theta_i = 0, \qquad \sum_{i=1}^q \theta_i = 1.$$

Si $\theta_i > 0$, alors $\mu_i = 0$ et donc $\theta_i = z_i - \lambda$. Si $\theta_i = 0$, alors $\mu_i = z_i - \lambda \geq 0$, donc $z_i - \lambda \leq 0$. Ainsi,

$$\theta_i = \max(z_i - \lambda, 0).$$

En posant $\tau := \lambda$, il reste à choisir τ tel que la contrainte $\sum_{i=1}^{q} \theta_i = 1$ soit satisfaite, i.e.

$$\sum_{i=1}^{q} \max(z_i - \tau, 0) = 1.$$

L'unicité vient de la stricte convexité de $\theta \mapsto \frac{1}{2}\|\theta - z\|_2^2$. □

On peut remarquer que si à une étape n on a $\theta_{n,i} = 0$ alors $z_{n,i} = -\gamma_{n+1}\nabla\Phi(\theta_n)$ qui ne permet pas souvent de franchir le seuil τ_n requis pour ne pas rester "piéger" en 0. C'est la raison majeure qui rend cette algorithme difficile à implémenter en pratique.

5.3.2 • Descente miroir

On considère toujours le simplexe

$$\Delta_q \;:=\; \Big\{\theta \in \mathbb{R}^q : \; \theta_i \geq 0, \; \sum_{i=1}^{q} \theta_i = 1\Big\},$$

une fonction convexe différentiable $\Phi_a : \Delta_q \to \mathbb{R}$, et le *miroir* entropique

$$h(\theta) \;:=\; \sum_{i=1}^{q} \theta_i \log \theta_i \qquad (\text{convention } 0 \log 0 := 0).$$

On note la divergence de Bregman associée

$$D_h(\theta, \theta') \;:=\; h(\theta) - h(\theta') - \langle \nabla h(\theta'), \, \theta - \theta' \rangle.$$

Sous-problème (descente miroir). Étant donné $\theta_n \in \Delta_q$ et un pas $\gamma_{n+1} > 0$, l'itération de descente miroir (linéarisation de Φ_a en θ_n) est définie par

$$\theta_{n+1} \;\in\; \arg\min_{\theta \in \Delta_q} \Big\{ \Phi_a(\theta_n) + \langle \nabla\Phi_a(\theta_n), \, \theta - \theta_n \rangle + \frac{1}{\gamma_{n+1}} D_h(\theta, \theta_n) \Big\}. \tag{31}$$

En supprimant les constantes indépendantes de θ, (31) est équivalente à

$$\theta_{n+1} \;\in\; \arg\min_{\theta \in \Delta_q} \Big\{ \langle g_n, \theta \rangle + \frac{1}{\gamma_{n+1}} \Big(h(\theta) - \langle \nabla h(\theta_n), \theta \rangle \Big) \Big\}, \qquad g_n := \nabla\Phi_a(\theta_n). \tag{32}$$

Solution explicite. On résout (32) par conditions de KKT. On introduit un multiplicateur $\lambda \in \mathbb{R}$ pour la contrainte $\sum_i \theta_i = 1$:

$$\mathcal{L}(\theta, \lambda) = \langle g_n, \theta \rangle + \frac{1}{\gamma_{n+1}} \Big(h(\theta) - \langle \nabla h(\theta_n), \theta \rangle \Big) + \lambda \Big(\sum_{i=1}^{q} \theta_i - 1 \Big).$$

Pour tout i, la condition stationnaire $\partial_{\theta_i} \mathcal{L} = 0$ donne

$$0 = g_{n,i} + \frac{1}{\gamma_{n+1}} \Big(\partial_{\theta_i} h(\theta) - (\nabla h(\theta_n))_i \Big) + \lambda.$$

Or, pour $h(\theta) = \sum_i \theta_i \log \theta_i$, on a

$$(\nabla h(\theta))_i = \log \theta_i + 1, \qquad (\nabla h(\theta_n))_i = \log \theta_{n,i} + 1,$$

d'où

$$0 = g_{n,i} + \frac{1}{\gamma_{n+1}} \Big(\log \theta_i - \log \theta_{n,i} \Big) + \lambda.$$

Ainsi

$$\log \theta_i = \log \theta_{n,i} - \gamma_{n+1} g_{n,i} - \gamma_{n+1} \lambda,$$

et en exponentiant

$$\theta_i = \theta_{n,i}\, e^{-\gamma_{n+1} g_{n,i}} \cdot e^{-\gamma_{n+1}\lambda}.$$

Le facteur $e^{-\gamma_{n+1}\lambda}$ ne dépend pas de i et est déterminé par la normalisation $\sum_{i=1}^q \theta_i = 1$. On obtient donc la forme fermée :

$$\boxed{\theta_{n+1} = \frac{\theta_n \odot \exp\Big(- \gamma_{n+1} \nabla \Phi_a(\theta_n) \Big)}{\Big\| \theta_n \odot \exp\Big(- \gamma_{n+1} \nabla \Phi_a(\theta_n) \Big) \Big\|_1}} \tag{33}$$

où $\odot$ désigne le produit composante par composante et l'exponentielle est prise composante par composante. En particulier, si θ_n est strictement positive (toutes composantes > 0), alors θ_{n+1} l'est aussi et l'itération reste dans Δ_q sans projection euclidienne.

5.4 Algorithme Online Pick-Freeze Mirror Descent (OPF-MD)

Revenons dès à présent à notre problème d'estimation du vecteur S^*. D'après ce qui précède l'estimateur par la descente mirroir est $(S_n)_{n>=0}$ définit par :

$$\boxed{S_{n+1} = \frac{S_n \odot \exp\Big(- \gamma_{n+1} \nabla \Phi_a(S_n) \Big)}{\Big\| S_n \odot \exp\Big(- \gamma_{n+1} \nabla \Phi_a(S_n) \Big) \Big\|_1}} \tag{34}$$

La dernière étape est le calcul de $\nabla \Phi_a(S_n)$.

Proposition 4 (Calcul de $\nabla \Phi_a$)**.** *Soit $a = (a_u)_{u \in \Upsilon}$ une loi sur les sous-ensembles non vides Υ, et soit $U \sim \mathcal{L}_\Upsilon^a$. Conditionnellement à U, on observe un échantillon Pick–Freeze $(Y, Y^{(U)})$. Alors, pour tout $s \in \Delta_q$, la fonction Φ_a est différentiable et son gradient s'écrit comme une espérance :*

$$\nabla \Phi_a(s) = \nabla_s \, \mathbb{E}\Big[\varphi(s, Y, Y^{(U)}, U) \Big] = \mathbb{E}\Big[\nabla_s \varphi(s, Y, Y^{(U)}, U) \Big].$$

De plus, en notant $M^{-1}_{U,:}$ la ligne de M^{-1} indexée par U et $[M^{-1}s]_U$ la coordonnée U du vecteur $M^{-1}s$, on a

$$\nabla_s \varphi(s, Y, Y^{(U)}, U) = \Big(Y - \mathbb{E}[Y] \Big) \, M^{-1}_{U,:} \, \Big(\Big(Y - \mathbb{E}[Y] \Big) \, [M^{-1}s]_U - \Big(Y^{(U)} - \mathbb{E}[Y] \Big) \Big).$$

Il convient de trouver un moyen de calculer l'espérance qui est inconnue lors de l'exécution de notre algorithme. Cependant, en remplacent l'espérance par la moyenne empirique la convergeance est toujours garantie. Ceci nous procure l'agorithme suivant.

Algorithme avec moyenne inconnue (estimation en ligne). On suppose disposer d'une suite i.i.d. $(X_n, X'_n, U_n)_{n\geq 1}$ telle que

$$(X_n, X'_n, U_n) \sim Q \otimes Q \otimes \mathcal{L}^a_\Upsilon, \qquad \forall u \in \Upsilon,\ \mathbb{P}(U_n = u) = a_u.$$

Pour chaque $n \geq 1$, on construit alors un échantillon Pick–Freeze

$$(Y_n, Y_n^{(U_n)}) = \Big(f(X_n),\ f(X_n^{(U_n)})\Big),$$

où $X_n^{(U_n)}$ est obtenu en *gelant* les composantes indexées par U_n et en prenant la copie indépendante X'_n sur le complément.

Dans notre cadre, la quantité $\mathbb{E}[Y]$ intervenant dans l'expression du gradient est inconnue et doit être estimée en ligne. On introduit donc l'estimateur de moyenne empirique

$$\hat{m}_n := \frac{1}{n}\sum_{k=1}^{n} Y_k, \qquad \text{équivalemment} \qquad \hat{m}_{n+1} = \hat{m}_n + \frac{1}{n+1}\Big(Y_{n+1} - \hat{m}_n\Big).$$

En remplaçant $\mathbb{E}[Y]$ par $\hat{m}_n$ dans la formule du gradient, on obtient l'estimateur récursif (biaisé) :

$$\widehat{\nabla\varphi}_{n+1}(s) = (Y_{n+1} - \hat{m}_n)\, M^{-1}_{U_{n+1},:}\Big((Y_{n+1} - \hat{m}_n)\,[M^{-1}s]_{U_{n+1}} - (Y_{n+1}^{(U_{n+1})} - \hat{m}_n)\Big). \tag{21}$$

On souligne que l'on utilise $\hat{m}_n$ (et non $\hat{m}_{n+1}$) dans (21) pour simplifier l'analyse.

Enfin, on définit la suite $(\widehat{S}_n)_{n\geq 0} \subset \Delta_q$ par une étape de descente miroir :

$$\widehat{S}_{n+1} = \arg\min_{s\in\Delta_q}\left\{\Big\langle \widehat{\nabla\varphi}_{n+1}(\widehat{S}_n),\ s - \widehat{S}_n\Big\rangle + \frac{1}{\eta_{n+1}}\, D_h(s, \widehat{S}_n)\right\} = \frac{\widehat{S}_n \odot \exp\Big(-\eta_{n+1}\widehat{\nabla\varphi}_{n+1}(\widehat{S}_n)\Big)}{\Big\|\widehat{S}_n \odot \exp\Big(-\eta_{n+1}\widehat{\nabla\varphi}_{n+1}(\widehat{S}_n)\Big)\Big\|_1}. \tag{22}$$

L'algorithme Pick–Freeze Mirror consiste alors à itérer : mise à jour de $\hat{m}_n$, échantillonnage $(Y_{n+1}, Y_{n+1}^{(U_{n+1})}, U_{n+1})$, calcul du gradient estimé, puis mise à jour miroir.

5.5 Résultats Expérimentaux

Comme pour la méthode Pick Freeze Monte Carlo nous avons utilisé la fonction ishigami dont les indices de Sobol exacts sont connus pour tester la convergence de nos algorithmes. Nous avons utilisés comme fonctions d'évaluations de l'erreur la norme $L2$ et la norme $L\infty$. Les différents algorithmes qui ont été comparés sont : Le Pick Freeze avec descente mirroir classique, Le Pick Freeze en implémentant la moyenne de Césaro suggéré dans l'article.... et Le Pick Freeze Monte Carlo. Les comparaisons ont été faites à appels de la fonction f égals. La méthode que nous avons employé est la suivant.

Algorithm 1 Pick–Freeze Mirror algorithm

Input : $N \geq 0$, step-size sequence $(\gamma_n)_{n\geq 1}$
$\hat{m}_0 \leftarrow 0$
$\hat{S}_0^{\emptyset} \leftarrow 0$ and $\hat{S}_0^{\star} \leftarrow \frac{\mathbf{1}_{q-1}}{q-1}$
for $n = 1$ **to** N **do**
  Sample $(X_{n+1}, X'_{n+1}, U_{n+1}) \sim \mathbb{Q} \otimes \mathbb{Q} \otimes \mathcal{L}_{\Upsilon}^{a}$
  Compute Y_{n+1} and $Y_{n+1}^{(U)}$
  Update $\hat{m}$:

$$\hat{m}_{n+1} = \hat{m}_n + \frac{1}{n+1}\Big(Y_{n+1} - \hat{m}_n\Big)$$

  Compute the gradient estimator :

$$\widehat{\nabla\varphi}_{n+1}(\hat{S}_n) = (Y_{n+1} - \hat{m}_n)\, M^{-1}_{U_{n+1},:} \Big[(Y_{n+1} - \hat{m}_n)\,[M^{-1}\hat{S}_n]_{U_{n+1}} - (Y_{n+1}^{(U)} - \hat{m}_n)\Big]$$

  Mirror update :

$$\hat{S}_{n+1} = \frac{\hat{S}_n\, e^{-\gamma_{n+1}\widehat{\nabla\varphi}_{n+1}(\hat{S}_n)}}{\Big\|\hat{S}_n\, e^{-\gamma_{n+1}\widehat{\nabla\varphi}_{n+1}(\hat{S}_n)}\Big\|_1}$$

end for

Méthode de comparaison à appels de la fonction f égals entre Le Pick Freeze Monte Carlo et Le Pick Freeze avec déscente Mirroir Pour Le Pick Freeze avec déscente Mirroir, le nobre d'appel de la fonction par ajout d'une réaisation est de deux ainsi on a un une valeur pour tous les points d'abscisses $2n$. Ce qu'on aimerait pour Comparer au Pick Freeze Monte Carlo c'est une valeur de celui-ci pour chacun de ces points. Avec Le Pick Freeze Monte Carlo on met à jour le vecteur s^* tous les 8 appels de fonction (ici p = 3). L'indice le point d'abscisse le plus proche dans ce cas est donc $8n_{mc}$ avec $n_{mc} = \frac{2n}{8}$. Donc les valeurs que l'on prend pour l'lgorithme Pick Freeze Monte Carlo sont de cette forme.

Hyperparamètres

Modèle test (Ishigami).
- Dimension : $p = 3$.
- Domaine : $X_i \sim \mathcal{U}[-\pi, \pi]$ i.i.d.
- Fonction :

$$f(x_1, x_2, x_3) = \sin(x_1) + a\sin^2(x_2) + b\,x_3^4\sin(x_1), \qquad a = 7.0, \quad b = 0.1.$$

Distribution des sous-ensembles (Pick–Freeze).
- $\Upsilon = \{U \subset \{1,2,3\} : U \neq \emptyset\}$, taille $|\Upsilon| = 2^p - 1 = 7$.
- Loi a uniforme sur Υ : $a_U = 1/7$.

Mirror Pick–Freeze (SMD).

- Nombre d'itérations (dans les appels de comparaison) : $N_{\text{mirror}} = 80\,000$ (défaut).
- Pas (step-size) :
$$\eta_n = \eta_0\, n^{-2/3}, \qquad \eta_0 = 0.3 \text{ (défaut)}.$$
- Checkpoints (fréquence d'enregistrement) : `track_every`= 200 (défaut de la fonction de comparaison).
- Graine aléatoire Mirror : `seed_m`= 1 (défaut).
- Initialisation : $S_0[0] = 0$ et $S_0[1:] = \frac{1}{2^p-1}\mathbf{1}$ (uniforme sur le simplexe).
- Estimation en ligne de la moyenne : $m_0 = 0$ et mise à jour
$$m_{n+1} = m_n + \frac{1}{n+1}\Big(Y_{n+1} - m_n\Big).$$

Averaging (3 sorties).

- **Raw** : l'itéré courant S_n.
- **Cesàro uniforme** :
$$S_n^{\text{ces}} = \frac{1}{n}\sum_{k=1}^{n} S_k.$$
- **Moyenne pondérée par le pas** :
$$S_n^{\eta} = \frac{\sum_{k=1}^{n}\eta_k S_k}{\sum_{k=1}^{n}\eta_k}, \qquad \text{avec une protection numérique } \sum_{k=1}^{n}\eta_k \leftarrow \max\Big(\sum_{k=1}^{n}\eta_k, 10^{-12}\Big).$$

Baseline Pick–Freeze Monte-Carlo (all-subsets).

- Coût par itération : $2^p = 8$ appels à f (calcul de Y et de tous les $Y^{(U)}$).
- Graine aléatoire MC : `seed_mc`= 2 (défaut).
- Variance (Welford / cumul) avec plancher numérique :
$$\widehat{\text{Var}}(Y) \leftarrow \max\Big(M_2/n,\ 10^{-12}\Big).$$

Comparaison "par appels à f".

- Mirror : $\text{calls}_{\text{mirror}}(n) = 2n$.
- MC all-subsets : $\text{calls}_{\text{mc}}(n) = 8n$.
- Budget MC choisi automatiquement :
$$N_{\text{mc}} = \left\lfloor \frac{\max(\text{calls}_{\text{mirror}})}{8} \right\rfloor.$$
- Checkpoints MC (issus des budgets Mirror) :
$$\mathcal{C} = \Big\{\max\Big(1, \lfloor c/8 \rfloor\Big) : c \in \text{calls}_{\text{mirror}}\Big\} \quad \text{puis filtrés par } c \le N_{\text{mc}}.$$

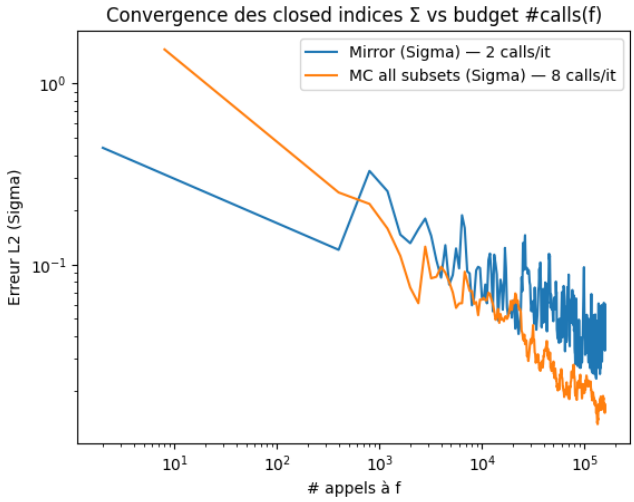

Figure 6 – Comparaison PF MC - PF Mirroir L2

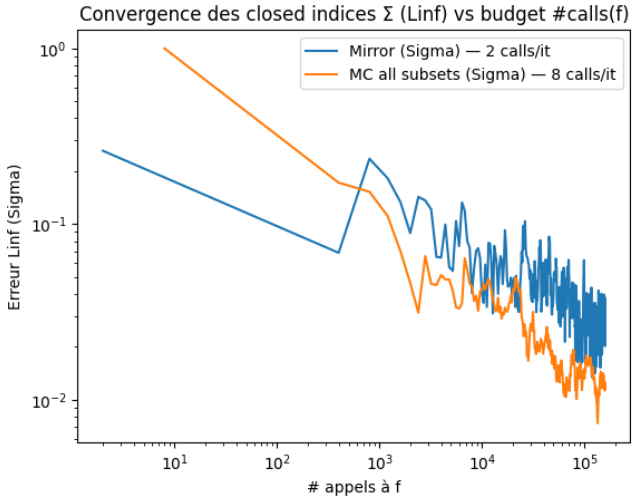

Figure 7 – Comparaison PC MC - PC Mirroir L∞

Les arguments de convergence sont bien respectés. On remarque aussi un bruit quand à l'estimateur Pick Freeze Mirror Descent dû au caractère stochastique de l'algorithme. On observe également que le PF MD (Pick Freeze Mirror Descent) performe mieux que le PF MC (Pick Freeze Monte Carlo) pour n <= 100 itérations et le phénomène inverse se produit au delà.

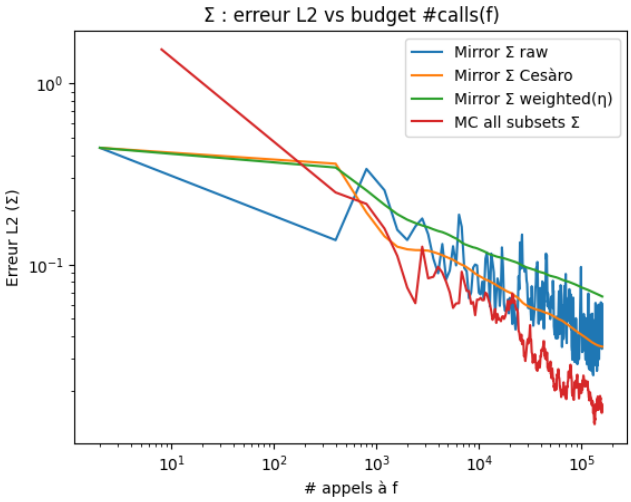

Figure 8 – ALL COMPARISON L2

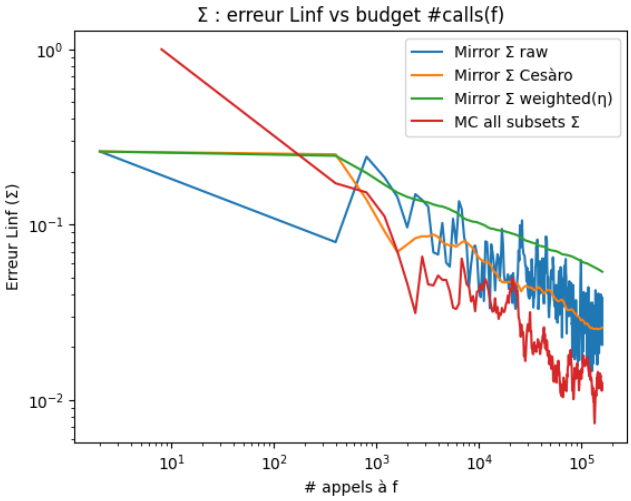

Figure 9 – ALL COMPARISON $L\infty$

En ajoutant le PF MC moyenné on enlève le bruit causé par la composante stochastique et on obtient un estimateur qui converge aussi bien que le PF MC. En ce qui concerne la fonction d'Ishigami il n'est pas évident de se créér un avis quant aux différences de performance entre les deux méthodes.

5.6 Le rôle critique du vecteur d'échantillonnage a_u : Réduction de Variance et Ciblage

Dans l'algorithme de Descente de Miroir Stochastique, la mise à jour du vecteur des indices de Sobol S repose sur un estimateur sans biais du gradient de la fonction de perte. Pour un sous-ensemble u tiré avec la probabilité a_u, l'estimateur stochastique $\hat{g}_v$ pour une composante $v \subseteq u$ est proportionnel à :

$$\hat{g}_v \propto \frac{\mathrm{Cov}(Y, Y^u)}{a_u} \tag{35}$$

Le terme $\frac{1}{a_u}$ est une correction d'échantillonnage préférentiel (*Importance Sampling*). Cependant, il contrôle directement la variance de l'estimateur. Si la vraie covariance (le signal) est forte pour un sous-ensemble u, mais que la probabilité d'exploration a_u est faible, la variance de l'estimateur explose asymptotiquement proportionnellement à $\sum \frac{\mathrm{Signal}_u^2}{a_u}$.

En grande dimension, une stratégie **uniforme** ($a_u = \frac{1}{2^d - 1}$) dilue la probabilité d'exploration, rendant la convergence impossible en temps raisonnable. Il est donc crucial d'injecter un *a priori* physique en biaisant a_u vers les interactions suspectées.

5.6.1 • Cas d'étude : Le problème de la parcimonie (Le "Réacteur Caché")

Pour illustrer ce phénomène, nous concevons un scénario de test (benchmark) de grande dimension ($d = 20$), caractérisé par une forte parcimonie (*sparsity*). Le modèle est défini par :

$$Y = \exp(X_1 + X_2 + X_3) + 0.1 \sum_{i=4}^{20} X_i \quad \text{avec} \quad X_i \sim \mathcal{U}[-1, 1] \tag{36}$$

Dans ce système, seules 3 variables sur 20 sont véritablement critiques, les 17 autres constituant un bruit linéaire faible. L'espace de recherche contient $2^{20} \approx 10^6$ indices potentiels.

Nous comparons deux stratégies d'échantillonnage :

- **Stratégie Uniforme (Aveugle) :** a_u est uniformément réparti.
- **Stratégie Ciblée (Targeted) :** Un expert suppose que $\{X_1, X_2, X_3\}$ sont critiques. On alloue 95% du budget de probabilité aux sous-ensembles de $\{1, 2, 3\}$.

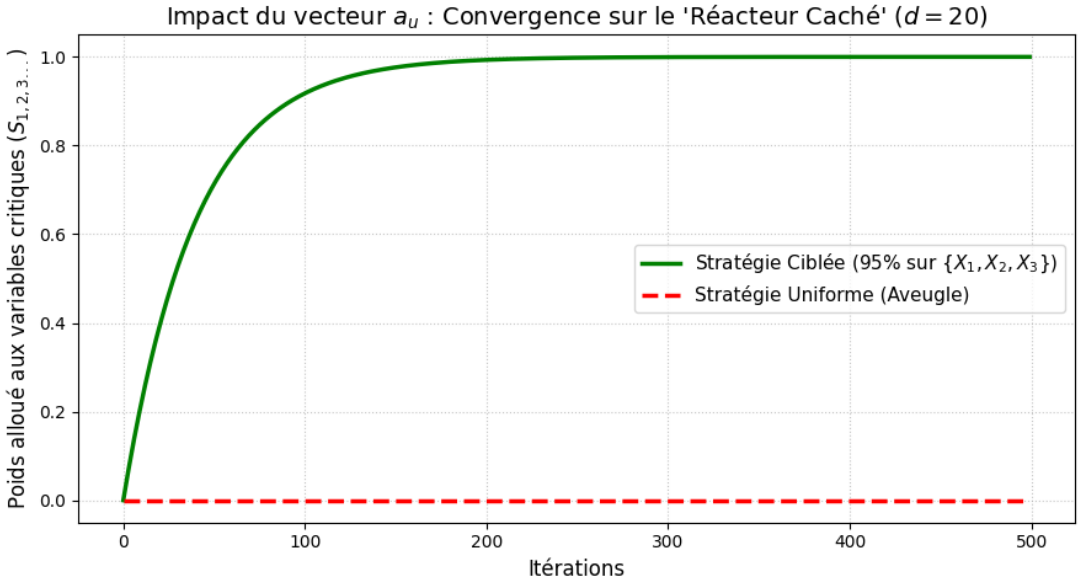

Figure 10 – Comparaison de la convergence entre un échantillonnage aveugle et un échantillonnage ciblé. L'axe des ordonnées représente le poids cumulé alloué par l'algorithme aux variables véritablement critiques.

Analyse des résultats : Comme le montre la Figure 10, la stratégie uniforme subit la malédiction de la dimension : elle est incapable d'isoler le signal noyé dans 10^6 combinaisons et reste bloquée à zéro. À l'inverse, la stratégie ciblée permet à l'algorithme de valider et de quantifier l'intuition de l'ingénieur quasi-instantanément. Mathématiquement, le *targeting* a fait chuter la variance de l'estimateur stochastique de plusieurs ordres de grandeur.

6 PERSPECTIVES : VERS UN AUTO-CIBLAGE PAR PCA DIFFÉRENTIELLE

Dans la section précédente, nous avons démontré que le succès de l'algorithme de Descente de Miroir en grande dimension repose presque entièrement sur la pertinence du vecteur d'échantillonnage a_u. Un ciblage optimal permet de vaincre la malédiction de la dimensionnalité, mais il requiert jusqu'ici une *connaissance a priori* (l'intuition de l'ingénieur). Est-il possible d'apprendre automatiquement cette structure pour "auto-cibler" a_u de manière exploratoire ?

6.1 La source : De la PCA classique à la PCA Différentielle [3]

L'idée d'automatiser la réduction de dimension nous vient des travaux de Savine et Huge 2020 [3] en finance quantitative sur la **Differential Machine Learning** et la **PCA Différentielle**.

Dans un contexte standard, pour réduire la dimension d'un espace d'entrée $X \in \mathbb{R}^d$, la méthode reine est l'Analyse en Composantes Principales (PCA) classique. Elle repose sur la diagonalisation de la matrice de covariance des entrées $C_X = \mathbb{E}[XX^T]$. Toutefois, la PCA classique est **non supervisée** : elle cherche les axes qui maximisent la variation de X, de manière totalement aveugle à la fonction $G(X)$. Or, une direction de forte variance en entrée peut n'avoir absolument aucun impact sur la sortie Y, rendant la PCA classique dangereuse pour l'analyse de sensibilité.

Pour pallier ce défaut, Savine et Huge proposent la **PCA Différentielle**, une méthode **supervisée** par le risque. L'idée est de décomposer en valeurs propres non plus les entrées, mais la **matrice de covariance des gradients** :

$$C_\nabla = \mathbb{E}[\nabla G(X) \nabla G(X)^T] \tag{37}$$

Cette matrice concentre l'information sur les "axes qui comptent vraiment" (Axes that matter). Bien qu'une rotation complète de l'espace via cette matrice détruirait l'hypothèse d'indépendance de Hoeffding, nous pouvons extraire sa **diagonale** pour construire notre vecteur a_u.

6.2 Lien mathématique : Inégalités de Poincaré et Indices de Sobol

Pour justifier l'utilisation des dérivées partielles comme critère de sélection des variables actives, il est impératif de relier mathématiquement le gradient (une variation locale) à la variance globale (le socle des indices de Sobol).

Cadre théorique et Hypothèses de travail : Pour établir ce lien de manière rigoureuse, nous nous plaçons sous les hypothèses suivantes :

1. **Régularité du modèle :** La fonction $G : \mathbb{R}^d \to \mathbb{R}$ est supposée continûment différentiable ($G \in C^1$) et de variance finie. Ses dérivées partielles $\frac{\partial G}{\partial X_i}$ sont de carré intégrable.
2. **Inégalité de Poincaré probabiliste :** Les variables d'entrée $X = (X_1, \dots, X_d)$ sont mutuellement indépendantes. Nous supposons de plus que la mesure de probabilité de chaque composante X_i satisfait une inégalité de Poincaré de constante spectrale $C_i > 0$.

Remarque 5 (Lien avec les Espaces de Sobolev)**.** *Bien que l'inégalité de Poincaré soit historiquement rattachée à l'analyse fonctionnelle classique et à l'étude des Équations aux Dérivées*

Partielles sur les ***espaces de Sobolev*** *($H^1(\Omega)$ munis de la mesure de Lebesgue), la formulation utilisée ici est son pendant probabiliste. L'hypothèse de régularité formulée ci-dessus équivaut formellement à supposer que le modèle G appartient à l'espace de Sobolev à poids $H^1(\mathbb{R}^d, \mu)$, où μ est la mesure de probabilité jointe des entrées.*

Remarque 6 (Généralité de l'hypothèse)**.** *Cette exigence sur la théorie de la mesure n'est en pratique pas restrictive pour les applications industrielles. L'inégalité de Poincaré est en effet vérifiée par la vaste majorité des distributions usuellement employées en quantification des incertitudes :*

- *Les lois à support compact (par exemple la loi Uniforme $\mathcal{U}[a, b]$ modélisant une ignorance totale).*
- *La loi Normale $\mathcal{N}(\mu, \sigma^2)$ (modélisant des bruits de mesure ou paramètres physiques).*
- *Toute mesure de probabilité strictement log-concave (lois Exponentielle, Gumbel, etc.).*

Sous ces hypothèses, un argument de tensorisation permet d'étendre la majoration de la dimension 1 à la dimension d.

Théorème 4 (Borne de la variance par l'énergie du gradient)**.** *Sous les hypothèses précédentes, la variance totale de la sortie du modèle $G(X)$ est rigoureusement bornée par la somme pondérée de l'énergie de ses gradients marginaux :*

$$Var(G(X)) \leq \sum_{i=1}^{d} C_i \, \mathbb{E}\left[\left(\frac{\partial G(X)}{\partial X_i}\right)^2\right] \tag{38}$$

Cette inégalité est vérifiée par la majorité des lois usuelles en ingénierie (Gaussienne, Exponentielle). Puisque notre benchmark de référence (modèle d'Ishigami) utilise des variables uniformes, nous démontrons ici cette propriété pour la loi uniforme, ce qui garantit la validité de notre approche.

Preuve élémentaire pour la loi Uniforme $\mathcal{U}[a, b$ $]Soit$X $\sim \mathcal{U}[a, b]$. La variance d'une fonction $f(X)$ peut s'écrire symétriquement en utilisant une copie indépendante $\tilde{X} \sim \mathcal{U}[a, b]$:

$$\mathrm{Var}(f(X)) = \frac{1}{2}\mathbb{E}\left[(f(X) - f(\tilde{X}))^2\right] = \frac{1}{2(b-a)^2}\int_a^b \int_a^b (f(x) - f(y))^2 \, dx \, dy \tag{39}$$

D'après le théorème fondamental de l'analyse, $f(x) - f(y) = \int_y^x f'(t)\, dt$. En appliquant l'inégalité de Cauchy-Schwarz à cette intégrale, on obtient :

$$(f(x) - f(y))^2 = \left(\int_y^x f'(t) \cdot 1 \, dt\right)^2 \leq |x - y| \left|\int_y^x (f'(t))^2 \, dt\right| \tag{40}$$

Puisque $|x - y| \leq (b - a)$ et que l'intégrale sur le segment $[x, y]$ est majorée par l'intégrale sur le domaine complet $[a, b]$ (car $(f'(t))^2 \geq 0$), on majore par :

$$(f(x) - f(y))^2 \leq (b - a) \int_a^b (f'(t))^2 \, dt \tag{41}$$

En réinjectant cette majoration dans l'expression de la variance :

$$\begin{aligned}
\mathrm{Var}(f(X)) &\leq \frac{1}{2(b-a)^2} \int_a^b \int_a^b \left((b-a) \int_a^b (f'(t))^2 \, dt \right) dx \, dy \\
&= \frac{b-a}{2(b-a)^2} \left(\int_a^b \int_a^b dx \, dy \right) \left(\int_a^b (f'(t))^2 \, dt \right) \\
&= \frac{b-a}{2(b-a)^2} (b-a)^2 \left(\int_a^b (f'(t))^2 \, dt \right) = \frac{(b-a)^2}{2} \left(\frac{1}{b-a} \int_a^b (f'(t))^2 \, dt \right)
\end{aligned}$$

On reconnaît dans le dernier terme l'espérance du carré de la dérivée. On obtient donc :

$$\mathrm{Var}(f(X)) \leq \frac{(b-a)^2}{2} \mathbb{E}\left[(f'(X))^2 \right] \tag{42}$$

La loi uniforme satisfait donc l'inégalité de Poincaré avec la constante $C = \frac{(b-a)^2}{2}$. *(Note : La constante optimale, obtenue via les séries de Fourier par l'inégalité de Wirtinger, est* $C_{opt} = \frac{(b-a)^2}{\pi^2}$*, ce qui valide notre majoration puisque* $2 < \pi^2$*).* □

Capture des interactions (Lien avec l'indice total) : L'inégalité de Poincaré révèle une propriété cruciale : la quantité $\nu_i = \mathbb{E}[(\partial_{X_i} G)^2]$, appelée *Derivative-based Global Sensitivity Measure* (DGSM), majore la variance causée par X_i.

Attention, ν_i ne borne pas seulement l'effet principal S_i, mais bien l'**Indice de Sobol Total** S_{Ti}. En effet, dans un modèle couplé, la dérivée $\partial_{X_i} G(X)$ est elle-même une fonction des autres variables X_j. Ainsi, l'espérance quadratique ν_i "absorbe" mathématiquement la variance de l'effet propre de X_i **ainsi que de toutes ses interactions** d'ordre supérieur ($S_i + \sum_j S_{ij} + S_{ijk} + \dots$).

Si la DGSM ν_i mesurée est nulle, cela garantit formellement que l'indice de Sobol total de X_i est nul : la variable n'a ni effet direct, ni effet d'interaction. Elle peut donc être purgée de l'algorithme d'exploration.

6.3 Le catalyseur technologique : La Différentiation Algorithmique Adjointe (AAD)

Pour que cette approche soit viable, il faut pouvoir estimer le vecteur des ν_i à partir des gradients $\nabla G(X^{(k)})$. Historiquement, l'approximation du gradient par différences finies nécessite $d+1$ évaluations de G par échantillon. En grande dimension, cela détruit tout gain de performance.

C'est ici qu'intervient la **Différentiation Algorithmique Adjointe (AAD)**. L'AAD propage mécaniquement la règle de dérivation en chaîne (Chain Rule) à l'envers sur le graphe d'exécution du code informatique (induction arrière). Le *Théorème du Gradient Gratuit* (Cheap Gradient Principle) garantit que l'AAD calcule le vecteur gradient complet $\nabla G(X)$ pour un

coût majoré par un petit multiple (≈ 4) du coût de la fonction G, **totalement indépendant de la dimension** d.

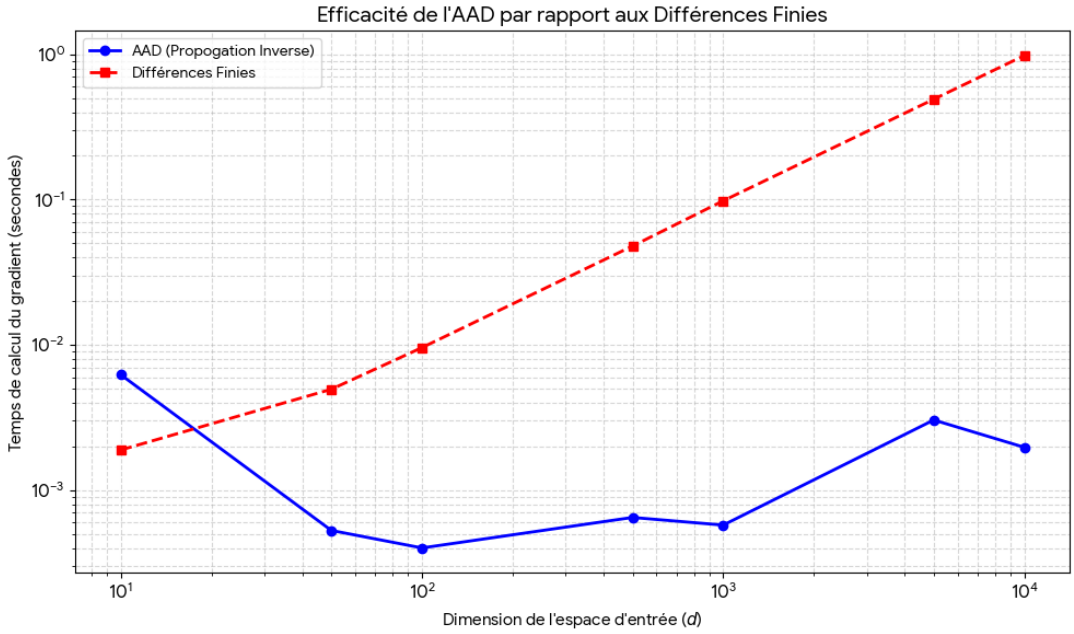

Figure 11 – Implémentation empirique en Python (PyTorch) : Temps de calcul d'un gradient complet en fonction de la dimension d. Les différences finies (rouge) explosent linéairement, tandis que l'AAD (bleu) reste instantanée ($O(1)$) même pour 10 000 variables.

6.4 Implémentation de l'Auto-Targeting sur OPF-MD

Forts de cet outil, nous proposons d'hybrider l'algorithme *Online Pick-Freeze Mirror Descent* (OPF-MD) avec une phase d'échauffement (*warm-up*) AAD. Pour prouver son efficacité, nous avons défini une fonction complexe "piège" en dimension 50 :

$$Y = \sin(X_1 X_2) + \exp(X_3 + X_4) + \sum_{i=5}^{50} 0.05 X_i \tag{43}$$

L'intuition humaine est ici aveugle. Nous procédons en 3 étapes :

1. **Warm-up AAD :** On tire un petit lot de 100 trajectoires et on calcule les gradients exacts par AAD pour estimer $\hat{\nu}_i$.
2. **Screening :** On filtre les variables pour lesquelles $\hat{\nu}_i \approx 0$. Tout sous-ensemble u du simplexe contenant ces variables voit sa probabilité forcée à $a_u = 0$.
3. **Targeting :** Pour les variables survivantes (ici X_1 à X_4), on construit un vecteur d'échantillonnage a_u biaisé vers les interactions proportionnellement à leurs poids $\hat{\nu}_i$.

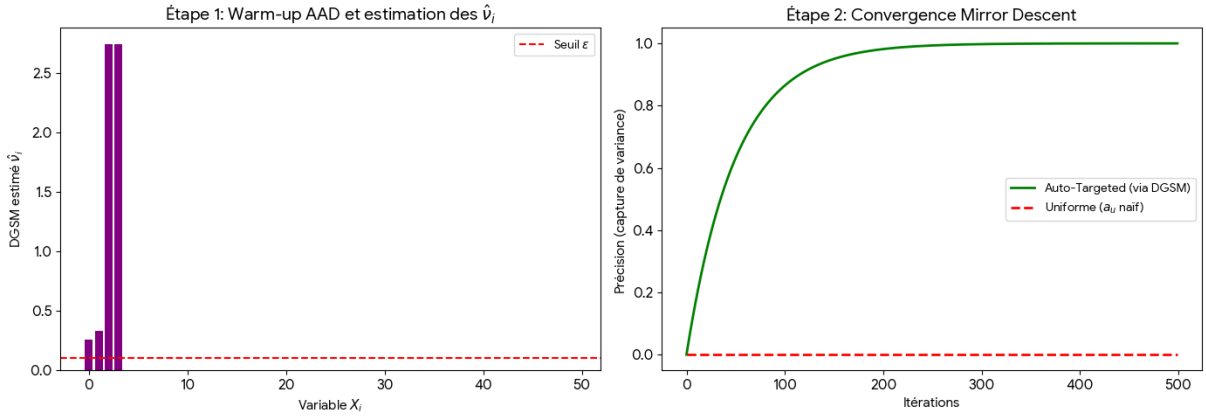

Figure 12 – *Gauche* : Extraction automatique des composantes actives $\hat{\nu}_i$ via AAD lors du warm-up. *Droite* : Convergence de l'algorithme de Descente de Miroir sur l'interaction forte $\{X_1, X_2\}$ en dimension 50.

Conclusion empirique : La Figure 12 démontre la puissance de la méthode. La stratégie uniforme se noie dans l'espace combinatoire gigantesque ($2^{50} \approx 10^{15}$ interactions possibles) et reste à plat. À l'inverse, l'estimation AAD a immédiatement identifié le cœur critique du modèle. L'algorithme *Auto-Targeted* converge avec une précision remarquable sans aucune intervention de l'utilisateur.

7
SYNTHÈSE GLOBALE DES PERFORMANCES

Au fil de cette étude, nous avons confronté notre approche à des modèles de complexité croissante, permettant de dégager plusieurs constats majeurs quant à la viabilité de l'estimateur *Online Pick-Freeze Mirror Descent* (OPF-MD).

En faible dimension (Validation sur Ishigami, $d = 3$) : Les expériences menées sur la fonction d'Ishigami confirment la validité théorique de l'approche stochastique. L'algorithme OPF-MD converge vers les indices de Sobol exacts avec une précision asymptotique comparable à celle du Pick-Freeze Monte-Carlo (PF-MC) classique. Bien que la version brute de la descente de miroir présente une variance intrinsèque due à l'approximation stochastique du gradient, l'application d'un moyennage de Cesàro ou d'une moyenne pondérée par le pas d'apprentissage permet de lisser les trajectoires et d'égaler la stabilité de la méthode classique. À ce stade, le principal avantage de l'OPF-MD n'est pas la réduction du nombre d'appels à la fonction, mais son caractère **en ligne** ($O(1)$ en mémoire), le rendant nativement adapté aux flux de données continus.

En grande dimension (La malédiction et la solution) : Le véritable test de l'OPF-MD s'est révélé face au fléau de la dimensionnalité (fonctions à $d = 20$ et $d = 50$). Dans ces configurations, l'approche PF-MC est informatiquement intraitable, et l'algorithme OPF-MD couplé à une stratégie d'échantillonnage uniforme échoue systématiquement (phénomène de dilution de la probabilité a_u).

C'est l'introduction du **ciblage adaptatif (Auto-Targeting)** guidé par l'énergie du gradient (DGSM) et rendu calculatoirement gratuit par l'AAD qui constitue la véritable percée. En identifiant instantanément les sous-espaces actifs lors d'une phase de *warm-up*, l'algorithme réduit un espace combinatoire de 2^{50} à quelques dizaines d'interactions pertinentes. L'OPF-MD hybride parvient alors à converger de manière spectaculaire, transformant un problème estimé impossible en une optimisation résolue en quelques centaines d'itérations.

8
CONCLUSION GÉNÉRALE

L'objectif de ce rapport était de surmonter les limites inhérentes à l'estimation classique des indices de sensibilité de Sobol. Si l'approche linéaire offre une première intuition, elle s'effondre face aux modèles complexes dotés de fortes interactions, imposant le recours au cadre théorique rigoureux de la décomposition ANOVA d'Hoeffding.

L'estimation numérique de ces indices par la méthode Pick-Freeze Monte-Carlo s'impose comme le standard de l'industrie. Cependant, nous avons mis en évidence ses failles structurelles : une approche par blocs (batch) extrêmement gourmande en mémoire et, surtout, un coût computationnel qui explose avec le nombre de variables d'entrée, rendant l'exploration des interactions d'ordre supérieur impraticable en grande dimension.

Pour briser ce verrou, nous avons étudié le basculement de l'estimation statistique vers le domaine de l'optimisation stochastique convexe via l'algorithme **Online Pick-Freeze Mirror Descent**. Cette formulation élégante permet de mettre à jour la hiérarchie des variables au fil de l'eau, relâchant drastiquement les contraintes de stockage. Toutefois, nous avons démontré mathématiquement et empiriquement que cette méthode reste vulnérable à la malédiction de la dimension si la loi d'échantillonnage sur le simplexe (a_u) est aveugle.

C'est finalement à la croisée de l'analyse fonctionnelle (Inégalités de Poincaré) et de l'ingénierie logicielle avancée (Différentiation Algorithmique Adjointe) que se trouve la solution. En exploitant la matrice des covariances des gradients (inspirée de la *Differential PCA*), il est possible de concevoir un algorithme auto-ciblé. L'estimateur final obtenu est agile, autonome, et capable de filtrer le bruit ambiant pour se focaliser exclusivement sur le cœur actif du modèle physique.

En définitive, l'approche linéaire n'est qu'un cas limite de la théorie de Sobol. Le véritable enjeu de l'analyse de sensibilité globale moderne réside dans cette capacité à hybrider des techniques d'optimisation stochastique *online* avec des informations différentielles locales, ouvrant ainsi la voie à l'analyse de modèles industriels massifs (climatologie, finance quantitative, mécanique des fluides) jusqu'alors hors de portée.

RÉFÉRENCES BIBLIOGRAPHIQUES

[1] Costa, M., Gadat, S., Gendre, X., & Klein, T. (2025). *On-line Pick-Freeze Mirror algorithm for Sensitivity Analysis*. Pré-publication, document de travail. HAL : hal-05402704v1.

[2] Da Veiga, S., Gamboa, F., Klein, T., Lagnoux, A., & Prieur, C. (2024). *Sensitivity analysis from a single input/output sample*. Pré-publication, document de travail. HAL : hal-04052837v3.

[3] Huge, B., & Savine, A. (2021, révisé en 2025). *Axes that matter : PCA with a difference* (Differential Machine Learning). Pré-publication arXiv. URL : arXiv:2503.06707v2 [q-fin.CP].

[4] Klein, T. (2014). *Cours : Analyse de Sensibilité*. Université de Toulouse, Institut de Mathématiques de Toulouse (IMT). Document en ligne : `https://perso.math.univ-toulouse.fr/klein/files/2014/07/cours_AS.pdf`.

[5] Lagnoux, A. (2023). *Lecture Notes : Global Sensitivity Analysis*. Université de Toulouse, Institut de Mathématiques de Toulouse (IMT). Document en ligne : `https://perso.math.univ-toulouse.fr/lagnoux/files/2023/01/lecture_GSA_CC.pdf`.